

SKRIPSI
KLASIFIKASI TUBERKULOSIS BERBASIS CITRA X-RAY
DADA DENGAN EXPLAINABLE AI MENGGUNAKAN
DENSENET121 DAN GRAD-CAM

Diajukan untuk memenuhi salah satu persyaratan memperoleh gelar sarjana

Teknik Informatika



Disusun oleh:

Nama : Muhammad Firdaus Sukma Adi

NIM : A11.2021.13396

Program Studi : Teknik Informatika

FAKULTAS ILMU KOMPUTER
UNIVERSITAS DIAN NUSWANTORO
SEMARANG

2025

PERSETUJUAN SKRIPSI

Nama : Muhammad Firdaus Sukma Adi
NIM : A11.2021.13396
Program Studi : S1 – Teknik Informatika
Fakultas : Teknik Informatika
Judul : Klasifikasi Tuberkulosis Berbasis Citra X-Ray Dada Dengan
Explainable AI Menggunakan Densenet121 dan Grad-CAM

Tugas Akhir ini telah diperiksa dan disetujui,

Semarang, 28 Juli 2025

Menyetujui:
Pembimbing



JUNTA ZENIARJA, M.Kom
NPP: 0686.11.2012.459

Mengetahui:
Dekan Fakultas Ilmu Komputer



SRI WINARNO, M.Kom., Ph.D.
NPP: 0686.11.1998.142

PENGESAHAN DEWAN PENGUJI


Nama : Muhammad Firdaus Sukma Adi
NIM : A11.2021.13396
Program Studi : S1 – Teknik Informatika
Fakultas : Teknik Informatika
Judul : Klasifikasi Tuberkulosis Berbasis Citra X-Ray Dada Dengan
Explainable AI Menggunakan Densenet121 dan Grad-CAM

Tugas akhir ini telah diujikan dan dipertahankan dihadapan Dewan Penguji pada
Sidang tugas akhir tanggal 28 Juli 2025. menurut pandangan kami, tugas akhir
Ini memadai dari segi kualitas maupun kuantitas untuk tujuan
penganugerahan gelar Sarjana Komputer (S.Kom)

Semarang, 28 Juli 2025

Dewan Penguji:

Anggota Penguji 1




CINANTYA PARAMITA, S.Kom., M.Eng
NPP: 0686.11.2015.616

Anggota Penguji 2



FILMADA OCKY SAPUTRA, M.Eng
NPP: 0686.11.2019.798

Ketua Penguji



Ir. Heru Agus Santoso, Ph.D., IPM., ASEAN Eng.
NPP: 0686.11.1998.165

**PERNYATAAN
KEASLIAN SKRIPSI**

Sebagai mahasiswa Universitas Dian Nuswantoro, yang bertanda tangan di bawah ini, saya:

Nama : Muhammad Firdaus Sukma Adi

NIM : A11.2021.13396

Menyatakan bahwa tugas akhir saya yang berjudul: **“Klasifikasi Tuberkulosis Berbasis Citra X-Ray Dada Dengan Explainable AI Menggunakan DenseNet121 Dan Grad-CAM”** merupakan karya asli saya (kecuali cuplikan dan ringkasan yang masing-masing telah saya jelaskan sumbernya). Apabila dikemudian hari, saya disinyalir bukan merupakan karya asli saya, yang disertai dengan bukti-bukti yang cukup, maka saya bersedia untuk dibatalkan gelar saya beserta hak dan kewajiban yang melekat pada gelar tersebut. Demikian surat pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Semarang

Pada tanggal : 28 Juli

Yang Menyatakan

Muhammad Firdaus Sukma Adi



**PERNYATAAN PERSETUJUAN
PUBLIKASI KARYA ILMIAH UNTUK KEPENTINGAN
AKADEMIS**

Sebagai mahasiswa Universitas Dian Nuswantoro, yang bertanda tangan di bawah ini, saya:

Nama : Muhammad Firdaus Sukma Adi

NIM : A11.2021.13396

Demi mengembangkan Ilmu Pengetahuan, menyetujui untuk memberikan kepada Universitas Dian Nuswantoro Hak Bebas Royalti Non-Eksklusif (Non- exclusive Royalty-Free Right) atas karya ilmiah saya yang berjudul: **“Klasifikasi Tuberkulosis Berbasis Citra X-Ray Dada Dengan Explainable AI Menggunakan DenseNet121 Dan Grad-CAM”** beserta perangkat yang diperlukan (bila ada). Dengan Hak Bebas Royalti Non Eksklusif ini Universitas Dian Nuswantoro berhak untuk menyimpan, mengcopy ulang (memperbanyak), menggunakan, mengelolanya dalam bentuk pangkalan data (database), mendistribusikannya dan menampilkan/mempublikasikannya di internet atau media lain untuk kepentingan akademis tanpa perlu meminta ijin dari saya selama tetap mencantumkan nama saya sebagai penulis/pencipta. Saya bersedia untuk menanggung secara pribadi, tanpa melibatkan pihak Universitas Dian Nuswantoro, segala bentuk tuntutan hukum yang timbul atas pelanggaran Hak Cipta dalam karya ilmiah saya ini. Demikian surat pernyataan ini saya buat dengan sebenarnya

Dibuat di : Semarang

Pada tanggal : 28 Juli

Yang Menyatakan

Muhammad Firdaus Sukma Adi



UCAPAN TERIMA KASIH

Puji syukur kepada Allah SWT yang telah memberikan rahmat dan karuniaNya sehingga penulis dapat menyelesaikan rangkaian Tugas Akhir yang berjudul “Klasifikasi Tuberkulosis Berbasis Citra X-Ray Dada Dengan Explainable AI Menggunakan Densenet121 dan Grad-CAM”. Laporan Tugas Akhir ini disusun sebagai salah satu syarat akademik untuk menyelesaikan studi di Program Studi S1 Teknik Informatika Universitas Dian Nuswantoro. Dalam proses penyusunan Tugas Akhir ini penulis mendapatkan semangat, dan motivasi serta arahan dari berbagai pihak. Penulis menyadari bahwa laporan ini tidak akan terwujud tanpa bantuan, dukungan, dan bimbingan dari berbagai pihak. Oleh karena itu, dengan tulus, saya mengucapkan terima kasih kepada:

1. Kedua Orang Tua serta Keluarga Besar yang senantiasa memberikan dukungan moral, materi, dan doa yang tulus dalam perjalanan akademik ini
2. Bapak Prof. Dr. Pulung Nurtantio Andono, S.T., M.Kom, selaku Rektor Universitas Dian Nuswantoro
3. Bapak Sri Winarno, Ph. D. selaku Dekan Fakultas Ilmu Komputer Universitas Dian Nuswantoro
4. Bapak Dr. Edy Mulyanto, S.Si., M.Kom. selaku Kepala Program Studi Teknik Informatika Universitas Dian Nuswantoro
5. Bapak Junta Zeniarja, M.Kom selaku Dosen Pembimbing Tugas Akhir yang telah meluangkan waktu untuk memberikan bimbingan dan arahan kepada penulis.
6. Seluruh Dosen Universitas Dian Nuswantoro yang telah berbagi ilmu dan pengalaman selama proses perkuliahan dari semester awal hingga akhir.
7. Teman-Teman seperjuangan dalam Tugas Akhir yang telah memberikan waktu, dan perhatiannya selama penulis menjalani tugas ini.
8. Seluruh pihak yang terlibat, terima kasih atas segala bantuannya baik di dalam pelaksanaan program, penyusunan laporan, maupun diluar program yang tidak dapat penulis sebutkan satu persatu.

Penulis menyadari bahwa laporan ini masih jauh dari sempurna. Oleh karena itu, penulis sangat mengharapkan kritik dan saran yang membangun dari berbagai pihak demi penyempurnaan laporan ini di masa yang akan datang. Akhir kata, penulis mengucapkan terima kasih atas segala perhatian dan kerja samanya, semoga hasil dari program ini dapat berguna serta bermanfaat bagi semua pihak yang sudah terlibat, terutama di Universitas Dian Nuswantoro, penulis, dan pembaca.

Semarang, 28 Juli 2025



Muhammad Firdaus Sukma Adi

ABSTRAK

Tuberkulosis (TBC) adalah penyakit menular yang disebabkan oleh *Mycobacterium tuberculosis*, terutama menyerang paru-paru dan menyebar melalui percikan dahak penderita aktif. Indonesia menempati posisi kedua terbanyak di dunia dalam jumlah kasus TBC. Deteksi dini sangat penting untuk mencegah komplikasi dan meningkatkan efektivitas pengobatan. Salah satu metode diagnosis yang umum digunakan adalah radiografi dada (X-ray), yang cepat dan terjangkau, namun sering terkendala keterbatasan tenaga medis. Penelitian ini bertujuan untuk mengembangkan sistem klasifikasi tuberkulosis menggunakan citra x-ray dada berbasis teknologi *deep learning*, khususnya menggunakan arsitektur *Convolutional Neural Network* (CNN) DenseNet121. Dataset yang digunakan adalah CXR (*Chest x-ray image*) berasal dari beberapa daerah dengan dua kelas, Normal dan Tuberkulosis. Total gambar yang digunakan berjumlah 2.104 yang telah melalui proses pre-processing kompleks termasuk segmentasi U-Net. Model dilatih menggunakan arsitektur DenseNet121 yang telah dikonfigurasi dan evaluasi menggunakan *confusion matrix*, *classification report*, dan ROC-AUC. Penelitian ini berhasil memperoleh hasil akurasi 94.29%, presisi 94.35%, *recall* 94.29%, *F1-score* 94,28%, dan nilai AUC sebesar 0,9751. Penelitian ini juga menerapkan visualisasi *explainable AI* menggunakan Grad-CAM untuk meningkatkan kepercayaan hasil klasifikasi. Penelitian ini menunjukkan bahwa pendekatan ini dapat menjadi solusi yang efektif dalam mendeteksi tuberkulosis secara otomatis melalui citra medis.

Kata Kunci: Klasifikasi Citra, Tuberkulosis, Convolutional Neural Network (CNN), DenseNet121, U-Net, Explainable AI, Grad-CAM.

DAFTAR ISI

PERSETUJUAN SKRIPSI	i
PENGESAHAN DEWAN PENGUJI.....	ii
PERNYATAAN KEASLIAN SKRIPSI.....	iii
PERNYATAAN PERSETUJUAN PUBLIKASI KARYA ILMIAH UNTUK KEPENTINGAN AKADEMIS	iv
UCAPAN TERIMA KASIH.....	v
ABSTRAK	vii
DAFTAR ISI.....	viii
DAFTAR GAMBAR	xi
DAFTAR TABEL	xii
BAB I PENDAHULUAN	1
1. 1 Latar Belakang	1
1. 2 Rumusan Masalah	6
1. 3 Batasan Masalah.....	6
1. 4 Tujuan Penelitian.....	8
1. 5 Manfaat Penelitian.....	8
1. 5. 1. Bagi Penulis.....	9
1. 5. 2. Bagi Pembaca	9
1. 5. 3. Bagi Tenaga Medis.....	9
1. 5. 4. Bagi Universitas	10
BAB II LANDASAN TEORI	11
2. 1 Tinjauan Studi	11
2. 1. 1 State of the art.....	11
2. 2 Tinjauan Pustaka	18
2. 2. 1 Tuberkulosis	18
2. 2. 2 Citra X-Ray Dada	20
2. 2. 3 Machine Learning.....	21

2. 2. 4	Deep Learning	22
2. 2. 5	Klasifikasi.....	23
2. 2. 6	Segmentasi Citra.....	24
2. 2. 7	Convolutional Neural Network (CNN)	25
2. 2. 8	DenseNet-121	26
2. 2. 9	U-Net	28
2. 2. 10	Explainable Artificial Intelligence (XAI).....	30
2. 2. 11	Transfer Learning	31
2. 2. 12	Pre-Processing	32
2. 2. 13	Python.....	34
2. 2. 14	Kaggle	34
2. 2. 15	Confusion Matrix	35
2. 2. 16	Classification Report	36
2. 2. 17	ROC dan AUC.....	38
2. 2. 18	Dice Coefficient	39
2. 3	Kerangka Pemikiran	41
BAB III METODE PENELITIAN.....		43
3. 1	Intrumen Penelitian	43
3. 1. 1	Informasi Data	44
3. 1. 2	Peralatan Penelitian	45
3. 2	Prosedur Pengumpulan Data	46
3. 2. 1	Observasi	46
3. 2. 2	Studi Pustaka	46
3. 3	Pre-processing Data.....	47
3. 4	Pembagian Data.....	49
3. 5	Arsitektur Model CNN	50
3. 5. 1	DenseNet-121	50
3. 5. 2	U-Net	51
3. 6	Explainable Artificial Intelligence (XAI).....	52
3. 7	Evaluasi	53

BAB IV HASIL PENELITIAN DAN PEMBAHASAN	54
4. 1 Eksplorasi Dataset	54
4. 1. 1 Dataset Segmentasi.....	55
4. 1. 2 Dataset Klasifikasi.....	57
4. 2 Pre-processing Data.....	58
4. 2. 1 Pembersihan	58
4. 2. 2 Resolusi, Resize, dan Normalisasi	59
4. 2. 3 Pembagian Data.....	60
4. 2. 4 Augmentasi.....	62
4. 2. 5 Segmentasi U-Net.....	63
4. 2. 6 Inferensi.....	65
4. 2. 7 Masking.....	65
4. 3 Konfigurasi Model DenseNet121	66
4. 4 Evaluasi Model.....	67
4. 4. 1 Confusion Matrix	68
4. 4. 2 Classification Report	69
4. 4. 3 ROC dan AUC.....	70
4. 4. 4 Dice Coefficient	71
4. 5 Explainable Artificial Intelligence (XAI).....	73
4. 6 Tabel Perbandingan	75
4. 7 Studi Ablasi	77
4. 8 Diskusi Penelitian.....	78
BAB V KESIMPULAN DAN SARAN.....	81
5. 1 Kesimpulan.....	81
5. 2 Saran	82
DAFTAR PUSTAKA	85

DAFTAR GAMBAR

Gambar 2. 1 Tuberkulosis (Vitrosens, 2023)	18
Gambar 2. 2 Citra X-ray Dada	20
Gambar 2. 3 Model CNN (Kristian Wilianto, 2021)	25
Gambar 2. 4 Arsitektur DenseNet121 (Wijaya Kusuma et al., 2023)	27
Gambar 2. 5 Dense Block (Wijaya Kusuma et al., 2023)	28
Gambar 2. 6 Arsitektur U-Net (Rahman et al., 2020)	28
Gambar 2. 7 Confusion Matrix	35
Gambar 2. 8 ROC dan AUC (Sarang Narkhede, 2018)	38
Gambar 3. 1 Flowchart Penelitian	43
Gambar 3. 2 Alur Pre-Processing Data	47
Gambar 3. 3 Arsitektur DenseNet121	50
Gambar 3. 4 Visualisasi Grad-CAM	52
Gambar 4. 1 Sampel X-ray Dada Berlabel Dataset Segmentasi	56
Gambar 4. 2 Sampel Mask	57
Gambar 4. 3 Sampel X-ray Dada Dataset Klasifikasi	58
Gambar 4. 4 UnderSampling Dataset Klasifikasi	59
Gambar 4. 5 Diagram Batang Distribusi Pembagian Dataset Segmentasi	61
Gambar 4. 6 Diagram Batang Distribusi Pembagian Dataset Klasifikasi	61
Gambar 4. 7 Sampel Augmentasi	63
Gambar 4. 8 Inferensi segmentasi U-Net	65
Gambar 4. 9 Hasil Evaluasi Confusion Matrix	68
Gambar 4. 10 Hasil Evaluasi Classification Report	70
Gambar 4. 11 Hasil Evaluasi ROC dan AUC	71
Gambar 4. 12 Hasil Evaluasi Dice Coefficient	72
Gambar 4. 13 Hasil Overlay Dice Coefficient	72
Gambar 4. 14 Visualisasi Grad-CAM	74

DAFTAR TABEL

Tabel 2. 1 State of the art	14
Tabel 2. 2 Kerangka Pemikiran.....	41
Tabel 3. 1 Informasi Data.....	44
Tabel 3. 2 Peralatan Penelitian.....	45
Tabel 4. 1 Distribusi Data	55
Tabel 4. 2 Sample Data MetaData.csv Dataset Segmentasi.....	56
Tabel 4. 3 Sample Data Metadata.xlsx Dataset Klasifikasi	57
Tabel 4. 4 Perbandingan Pembagian Data Penelitian	62
Tabel 4. 5 Parameter Augmentasi Data.....	62
Tabel 4. 6 Konfigurasi Model U-Net	63
Tabel 4. 7 Konfigurasi Pelatihan Model U-Net	64
Tabel 4. 8 Konfigurasi Model DenseNet121	66
Tabel 4. 9 Konfigurasi Pelatihan Model DenseNet121	67
Tabel 4. 10 Komparasi Penelitian Sebelumnya	75
Tabel 4. 11 Studi Ablasi.....	77

BAB I

PENDAHULUAN

1. 1 Latar Belakang

Penyakit yang melibatkan area dada seperti paru-paru, jantung, trakea, pembuluh darah besar dan struktur lainnya, menjadi salah satu penyebab utama morbiditas (penyakit atau gangguan kesehatan) dan mortalitas (kematian) secara umum. Menurut laporan World Health Organization (WHO), penyakit seperti tuberkulosis, kanker paru-paru, pneumonia, dan penyakit paru obstruktif kronik (PPOK) menjadi penyumbang terbesar angka kematian, tercatat terdapat 10,6 juta kasus tuberkulosis baru di seluruh dunia pada tahun 2022, (Kemenkes, 2021; World Health Organization, 2022). Tuberkulosis (TBC) merupakan salah satu penyakit menular yang masih menjadi masalah kesehatan global, terutama di negara berkembang yang disebabkan oleh infeksi bakteri *Mycobacterium tuberculosis*. Di Indonesia, TBC masih menjadi salah satu masalah kesehatan masyarakat dengan jumlah kasus yang terus meningkat dengan menempati peringkat kedua sebagai negara dengan beban TBC tertinggi di dunia (Sapto et al., 2021). Selain itu, tuberkulosis yang merupakan infeksi paru-paru, juga menjadi ancaman serius, terutama bagi kelompok rentan seperti anak-anak, lansia, dan individu dengan sistem kekebalan tubuh yang lemah (Dendi Maysanjaya, 2020). Penyakit ini tidak hanya membebani sistem kesehatan, tetapi juga memiliki dampak besar terhadap kualitas hidup masyarakat. Penanganan dan pencegahan yang efektif sangat diperlukan untuk mengurangi penyebarannya. Deteksi dini terhadap kelainan di area dada sangat penting untuk mencegah komplikasi serius dan meningkatkan keberhasilan pengobatan (Aviana et al., 2021). Kemajuan teknologi seperti X-ray memungkinkan profesional medis untuk mendiagnosis penyakit seperti tuberkulosis, pneumonia, dan lainnya secara lebih cepat dan akurat melalui analisis otomatis pada gambar X-ray dada (Leonard et al., 2024).

Radiografi dada (chest X-ray) menjadi alat diagnostik utama yang cepat, tidak invasif, dan terjangkau menjadikannya pendekatan yang banyak digunakan di daerah dengan sumber daya terbatas. Pemeriksaan ini memberikan gambaran rinci

tentang paru-paru, jantung, dan struktur dada lainnya untuk mendeteksi kelainan seperti infeksi, tumor, atau kerusakan jaringan. Gambaran radiologis TBC aktif pada X-ray meliputi infiltrasi lobus atas, kavitas berdinding tebal, konsolidasi, serta gambaran milier berupa nodul kecil yang tersebar. Namun, interpretasi hasil X-ray memiliki keterbatasan seperti kesalahan interpretasi manual, memerlukan keahlian radiolog yang terlatih, dan prosesnya sering memakan waktu cukup lama (Gefter et al., 2023). Kondisi ini menjadi semakin sulit di daerah terpencil atau wilayah dengan sumber daya terbatas, di mana tenaga medis spesialis sering kali tidak tersedia. Kemajuan teknologi seperti pembelajaran mesin (Machine Learning) menawarkan peluang besar dalam mendeteksi kelainan melalui data gambar X-ray secara cepat dan akurat, sehingga dapat membantu mengatasi berbagai kendala diagnostic (Kharis et al., 2024). Pendekatan ini bertujuan untuk meningkatkan akurasi deteksi, mempercepat diagnosis, dan mendukung tenaga kesehatan, terutama di daerah dengan keterbatasan sumber daya radiologi. Oleh karena itu, penelitian ini berfokus pada pengembangan metode deteksi otomatis TBC berbasis analisis citra medis menggunakan model machine learning untuk meningkatkan efektivitas deteksi dini TBC.

Pengimplementasian teknologi Machine Learning (ML) dapat memberikan pendekatan yang lebih akurat pada bidang analisis citra medis khususnya deteksi kelainan pada gambar X-ray (Kharis et al., 2024). Berbagai metode klasifikasi citra telah berkembang pesat dalam mendeteksi penyakit TBC pada gambar X-ray, seiring penerapan teknik-teknik modern. Convolutional Neural Network (CNN) menjadi salah satu teknik utama berkat kemampuannya mengekstraksi fitur penting secara otomatis dari gambar medis (Iqbal et al., 2023). Model berbasis transfer learning seperti DenseNet, EfficientNet, AlexNet, Inception V3, ResNet semakin meningkatkan kinerja CNN dengan mengoptimalkan pembelajaran dari dataset besar (Behzadi-khormouji et al., 2020). Selain itu, pendekatan segmentasi citra seperti DeepLabV3+, U-Net, SegNet memungkinkan pemodelan lebih terfokus pada area penting dalam gambar medis seperti paru-paru, yang menjadi pusat analisis dalam deteksi penyakit TB (Wahyuningrum et al., 2023). Sistem ini meningkatkan akurasi deteksi dengan menyoroti bagian gambar yang relevan dan

mengurangi gangguan dari informasi non-relevan(Iqbal et al., 2023). Disisi lain, penambahan mekanisme penjelasan hasil model berbasis kecerdasan buatan seperti Explainable Artificial Intelligence (XAI) seperti LIME, SHAP, dan Grad-CAM memberikan transparansi dalam proses pengambilan keputusan, membantu tenaga medis memahami dasar prediksi dan meningkatkan kepercayaan terhadap sistem(Truong Thanh Nguyen et al., 2021). Penggunaan XAI dalam ML mengalami kenaikan yang sangat signifikan khususnya di bidang kesehatan dengan pertumbuhan 10 kali lipat sejak 2009–2019(Bhandari et al., 2022), dan kenaikan lebih dari 90% publikasi pada 2020-2021(Di Martino and Delmastro, 2023). Tren ini mencerminkan urgensi untuk mengatasi masalah "black box" pada model ML/DL agar dapat diadopsi secara etis dan praktis termasuk untuk kasus tuberkulosis (TB) berbasis citra medis. Keseluruhan pendekatan ini memperluas peluang dalam meningkatkan akurasi diagnosis Tuberkulosis berbasis X-ray.

Berbagai arsitektur klasifikasi CNN seperti DenseNet, VGG, ResNet, Vision Transformer, MobileNet, dan EfficientNet, serta pendekatan hybrid, dan ensemble, telah menunjukkan keunggulan masing-masing dalam deteksi Tuberkulosis (TB) dari citra X-ray. CNN dan turunannya dikenal mampu mengekstraksi fitur spasial penting secara otomatis tanpa memerlukan tahapan pra-pemrosesan yang rumit, menjadikannya sangat efektif untuk analisis citra medis(Liu and Huang, 2020; Rahman et al., 2020). Selain itu, penggunaan Transfer Learning pada arsitektur seperti DenseNet dan ResNet memungkinkan adaptasi model secara cepat ke dataset TB yang umumnya relatif kecil, sambil tetap mempertahankan performa klasifikasi yang tinggi(Kim et al., 2022). Vision Transformer dan model hybrid yang menggabungkan CNN dan Transformer membawa kemampuan memahami struktur global dari citra X-ray paru-paru, yang penting untuk mendeteksi kelainan tersebar secara luas atau bercampur di berbagai area(T et al., 2023). Teknik ensemble learning, yang menggabungkan beberapa model sekaligus, mampu meningkatkan kemampuan generalisasi sistem dengan mengurangi risiko ketergantungan pada satu jenis pendekatan tertentu(Dietterich, 2000).

Meskipun menawarkan banyak keunggulan, berbagai metode ini juga menghadapi sejumlah tantangan. CNN dan arsitektur sejenis tetap bergantung pada

volume data pelatihan yang besar untuk mencapai generalisasi optimal, sehingga pada dataset kecil risiko overfitting meningkat. Vision Transformer, meskipun unggul dalam memahami hubungan global antar fitur, membutuhkan sumber daya komputasi yang jauh lebih tinggi, baik dari segi memori maupun waktu pelatihan. Model hybrid yang menggabungkan CNN dan Transformer sering kali memperbesar kompleksitas arsitektur, yang dapat memperpanjang waktu eksperimen dan memperbesar risiko kesalahan interpretasi hasil (T et al., 2023). Teknik ensemble memang meningkatkan akurasi, namun sebaliknya dapat memperberat kebutuhan komputasi dan mengurangi transparansi dalam memahami keputusan akhir model. Selain itu, interpretabilitas hasil tetap menjadi tantangan penting, mengingat sebagian besar model deep learning masih berfungsi sebagai "black box" yang sulit dijelaskan secara klinis kepada praktisi medis (Çallı et al., 2021). Dengan demikian, dalam memilih metode deteksi TB berbasis X-ray, perlu dipertimbangkan keseimbangan antara akurasi, efisiensi komputasi, kebutuhan interpretasi, dan ketersediaan sumber daya di lingkungan nyata.

Machine Learning dengan model klasifikasi pada gambar X-ray menawarkan potensi besar dalam mendeteksi tuberkulosis secara otomatis, sejumlah tantangan teknis masih harus dihadapi (Sharma et al., 2024). Salah satu hambatan utama adalah risiko overfitting akibat keterbatasan jumlah data medis berkualitas tinggi, yang membuat model cenderung menghafal pola daripada belajar generalisasi yang baik. Selain itu, variabilitas kualitas citra X-ray, baik akibat perbedaan alat, prosedur pengambilan gambar, maupun kondisi pasien, memperumit konsistensi prediksi. Imbalance kelas, di mana jumlah citra normal jauh lebih banyak dibandingkan citra positif TBC, juga dapat mengakibatkan bias model terhadap kelas mayoritas. Tidak kalah penting, variasi anatomi alami pada populasi dan kehadiran noise pada gambar menambah kompleksitas ekstraksi fitur yang akurat (Alfina et al., 2024; Hassan et al., 2025). Di sisi lain, penggunaan arsitektur model kompleks seperti CNN juga membawa tantangan komputasi tinggi dalam proses pelatihan dan inferensi, yang menjadi kendala terutama di lingkungan dengan sumber daya terbatas. Terakhir, pola radiologis TB pada X-ray dapat sangat mirip dengan penyakit lain seperti pneumonia, kanker paru, atau infeksi jamur,

sehingga meningkatkan risiko salah deteksi(Diar et al., 2022). Keseluruhan masalah ini harus dipertimbangkan dengan cermat untuk memastikan sistem deteksi TB berbasis X-ray dapat berfungsi secara andal di berbagai kondisi klinis. Oleh karena itu, diperlukan pendekatan yang tidak hanya berfokus pada akurasi, tetapi juga mampu mengatasi overfitting, meningkatkan efisiensi komputasi, memperbaiki ketidakseimbangan kelas, serta memperkuat ketahanan model terhadap variasi dan noise pada data X-ray.

Dengan adanya kekurangan dan masalah masalah yang muncul, perlu diatasi dengan berbagai strategi dapat diterapkan guna meningkatkan performa dan keandalan sistem deteksi tuberkulosis berbasis citra X-ray. Untuk mengurangi risiko overfitting, pendekatan seperti augmentasi data, early stopping, serta pengaturan parameter yang akan diintegrasikan dalam proses pelatihan model. Menghadapi keterbatasan komputasi, dipilihlah model dengan arsitektur yang lebih ringan seperti DenseNet yang tetap menjaga akurasi tanpa beban komputasi berlebih(Wijaya Kusuma et al., 2023). Selain itu, untuk mengatasi masalah ketidakseimbangan kelas, teknik oversampling, undersampling, atau penggunaan loss function berbobot akan diterapkan untuk mendorong model memperhatikan kelas minoritas. Dalam merespon variasi kualitas citra dan noise, digunakan teknik pre-processing seperti normalisasi, filtering, dan augmentasi adaptif agar model lebih robust terhadap gangguan visual. Sementara itu, untuk menanggapi variasi anatomi antar individu, model akan dilatih dengan data yang beragam guna meningkatkan generalisasi. Untuk mengurangi risiko salah deteksi akibat kemiripan TB dengan penyakit lain, penerapan threshold prediksi yang lebih ketat, disertai validasi manual pada prediksi yang ambigu, penggunaan dataset khusus menjadi solusi praktis yang efektif(Alfina et al., 2024). Dengan kombinasi pendekatan ini, diharapkan sistem deteksi TB berbasis X-ray dapat mencapai akurasi dan keandalan yang lebih tinggi. Pendekatan ini diharapkan dapat secara sinergis meningkatkan keakuratan dan keandalan dalam deteksi dini tuberkulosis berbasis klasifikasi citra X-ray.

Penelitian ini bertujuan untuk mengembangkan sistem deteksi otomatis Tuberkulosis (TBC) berbasis analisis citra X-ray dada menggunakan metode

klasifikasi berbasis Machine Learning. Fokus utama penelitian ini adalah membangun model yang mampu mendeteksi keberadaan TBC secara akurat, cepat, dan efisien. Untuk mencapai tujuan ini, penelitian akan menerapkan kombinasi strategi teknik augmentasi data, model lightweight seperti DenseNet, teknik balancing data, serta pre-processing adaptif untuk meningkatkan ketahanan model terhadap kualitas citra yang bervariasi. Selain itu, model akan dilatih dengan dataset yang beragam untuk meningkatkan kemampuan generalisasi terhadap populasi yang lebih luas. Penerapan XAI untuk pendukung keputusan dan transparansi model (Sharma et al., 2024). Dengan pendekatan ini, diharapkan sistem yang dikembangkan dapat memberikan kontribusi nyata dalam mendukung proses deteksi dini TBC, khususnya di lingkungan dengan keterbatasan sumber daya radiologi, serta mempercepat pengambilan keputusan klinis dengan tingkat keandalan yang tinggi.

1. 2 Rumusan Masalah

Dari latar belakang penelitian yang sudah dijelaskan diatas, kita dapat menyimpulkan beberapa tantangan yang menjadi focus penelitian ini untuk dipecahkan, yaitu:

1. Bagaimana mengembangkan sistem klasifikasi Tuberkulosis berbasis X-ray yang akurat, relevan, mampu mengatasi masalah overfitting, ketidakseimbangan kelas, variasi kualitas citra, variasi anatomi, serta noise?
2. Bagaimana meningkatkan transparansi pada model sehingga mendapatkan kepercayaan pada hasil deteksi Tuberkulosis berbasis X-ray dan membantu proses diagnosis?

1. 3 Batasan Masalah

Penelitian ini memiliki beberapa batasan yang bertujuan untuk mengfokuskan pada tujuan utama dan menghindari pembahasan yang terlalu luas atau terlalu sempit, sehingga pembahasan tidak melebar ke topik yang tidak sesuai dan memastikan tujuan utama tercapai. Batasan masalah pada penelitian ini mencakup:

1. Penelitian ini melakukan segmentasi dan klasifikasi, pada segmentasi menggunakan data gambar X-ray dada dari dua dataset publik, yaitu “Montgomery County Chest X-ray” berisi 138 gambar X-ray dada dari Montgomery County Department of Health, Montgomery County, Maryland, AS. dan “Shenzhen Chest X-ray” berisi 566 gambar X-ray dada dari Rumah Sakit Rakyat Shenzhen No. 3, China. Keduanya dapat ditemukan pada platform Kaggle dan disediakan oleh U.S. National Library of Medicine (NLM) dan Chinese National Tuberculosis Control Program. Dataset ini berisi gambar X-ray dada beserta mask segmentasi paru-paru dengan tipe data uint8 dalam format PNG. Ini diakses dengan URL: <https://www.kaggle.com/datasets/iamtapendu/chest-x-ray-lungs-segmentation> pada 14 Maret 2025/
2. Pada kasus klasifikasi digunakan dataset dengan judul “Tuberculosis (TB) Chest X-ray Database” yang diakses pada 27 Mei 2025 pada platform Kaggle dengan menggunakan URL: <https://www.kaggle.com/datasets/tawsifurrahman/tuberculosis-tb-chest-xray-dataset>. Dataset ini menggabungkan beberapa dataset antara lain, “Montgomery County Chest X-ray Dataset” sebanyak 138 gambar dan “Shenzhen Chest X-ray Dataset” sebanyak 662, belarus dataset yang mengandung 306 citra x-ray, RSNA CXR Dataset diambil 3094 citra x-ray normal dan berasal dari National Institutes of Health (NIH) Clinical Center, Amerika Serikat. Gabungan dataset ini menghasilkan 4200 gambar dengan 3500 gambar normal dan 700 gambar tuberkulosis. Dataset ini berisi gambar X-ray dada dengan tipe data uint8 dalam format PNG.
3. Model deep learning yang digunakan dalam penelitian ini difokuskan pada pengembangan sistem deteksi Tuberkulosis menggunakan arsitektur Convolutional Neural Networks (CNN) DenseNet121 dengan tambahan strategi peningkatan kinerja dan teknik handling class imbalance.
4. Penelitian ini dilakukan menggunakan Kaggle sebagai platform komputasi berbasis cloud untuk memproses data, melakukan training model, serta evaluasi kinerja.

5. Dataset yang digunakan dalam penelitian ini mencakup gambar X-ray dada yang sudah dilabeli sebagai TB-positive dan Normal, dengan klasifikasi berbasis diagnosis radiologis yang terpercaya. Dataset ini digunakan untuk keperluan penelitian, pengembangan, dan validasi model machine learning. Dataset ini diambil dari Kaggle di mana merupakan sumber yang terpercaya dan telah diolah untuk kepentingan penelitian dan machine learning.
6. Output dari penelitian ini adalah model klasifikasi untuk mendeteksi keberadaan Tuberkulosis berdasarkan citra X-ray dada dengan Grad-CAM untuk menyoroti bagian penting yang mempengaruhi hasil klasifikasi, serta evaluasi performa model menggunakan metrik akurasi, sensitivitas, spesifisitas, dan AUC (Area Under Curve).

1. 4 Tujuan Penelitian

Terdapat beberapa tujuan dari dilakukannya penelitian deteksi TBC terhadap data gambar X-ray dada ini, antara lain:

1. Mengembangkan dan mengoptimalkan sistem klasifikasi Tuberkulosis berbasis citra X-ray dada yang akurat dan relevan, dengan menerapkan teknik untuk mengatasi overfitting, ketidakseimbangan kelas, variasi kualitas gambar, variasi anatomi pasien, serta noise, guna meningkatkan kinerja dan keandalan model.
2. Merancang metode klasifikasi yang efektif dalam mendeteksi Tuberkulosis dengan memvisualisasikan peta aktivasi kelas dengan heat map menggunakan Grad-CAM untuk melihat bagian mana yang mendukung hasil klasifikasi.

1. 5 Manfaat Penelitian

Berdasarkan latar belakang yang telah dijelaskan sebelumnya, Penelitian ini diharapkan memberikan manfaat yang signifikan baik dalam aspek akademik, praktis, maupun sosial. Dengan memanfaatkan teknologi Machine Learning dan Explainable Artificial Intelligence dalam mendeteksi Tuberkulosis berbasis citra X-

ray dada, penelitian ini membuka peluang untuk pengembangan lebih lanjut di berbagai bidang. Berikut adalah manfaat yang diharapkan

1. 5. 1. Bagi Penulis

1. Memberikan kesempatan untuk memperdalam pengetahuan tentang teknologi deep learning untuk analisis citra medis, khususnya deteksi Tuberkulosis.
2. Mengasah kemampuan dalam mengelola data medis, melakukan pelatihan model, serta mengevaluasi performa sistem klasifikasi.
3. Meningkatkan keterampilan penelitian ilmiah, penulisan ilmiah, dan analisis data secara kritis, yang dapat dikembangkan untuk studi lanjut atau implementasi nyata di bidang teknologi kesehatan.

1. 5. 2. Bagi Pembaca

1. Memberikan wawasan baru tentang bagaimana penerapan deep learning dan XAI pada bidang radiologi, khususnya untuk deteksi penyakit Tuberkulosis.
2. Penelitian ini memberikan inspirasi, gambaran tantangan dan solusi bagi pembaca yang ingin membangun model klasifikasi citra medis untuk mendeteksi TBC berbasis Xray atau memperluas penelitian ke area medis lain berbasis citra medis.
3. Memperkaya pemahaman tentang cara kerja dan potensi model-model deep learning dalam membantu analisis medis secara komprehensif.

1. 5. 3. Bagi Tenaga Medis

1. Memperkenalkan alternatif sistem bantu diagnosis yang dapat mempercepat proses deteksi dini Tuberkulosis.
2. Teknologi yang digunakan dalam penelitian ini memungkinkan tenaga medis menganalisis citra X-ray dada secara lebih cepat dan efisien, dengan peningkatan efisiensi hingga 50%. Ini memungkinkan diagnosis dilakukan lebih dini, yang berpotensi menyelamatkan nyawa terutama di wilayah dengan keterbatasan sumber daya.

3. Memberikan kontribusi dalam mengurangi tingkat salah diagnosis Tuberkulosis yang sering terjadi akibat kemiripan pola radiografis dengan penyakit lain.

1. 5. 4. Bagi Universitas

1. Kontribusi nyata dalam pengembangan penelitian yang relevan dengan perkembangan teknologi terkini, terutama di bidang kecerdasan buatan untuk aplikasi medis, khususnya analisis citra radiologi.
2. Meningkatkan reputasi universitas sebagai institusi yang mendukung penelitian interdisipliner di bidang teknologi dan kesehatan serta berdampak nyata pada masyarakat.
3. Dapat membuka peluang kolaborasi dengan lembaga penelitian lain, rumah sakit, atau industri yang tertarik pada pengembangan solusi berbasis kecerdasan buatan.

BAB II

LANDASAN TEORI

2. 1 Tinjauan Studi

Terdapat beberapa penelitian terkait, yang dilakukan oleh peneliti sebelumnya dan digunakan pada penelitian ini sebagai landasan, referensi atau acuan oleh penulis dalam mendukung penelitian tentang deteksi penyakit Tuberkulosis menggunakan model CNN berbasis citra X-Ray. Dari referensi yang diambil memiliki persamaan pada objek dan metode.

2. 1. 1 State of the art

State of the art adalah sekumpulan kajian ilmiah yang berbentuk skripsi, tesis, disertasi, ataupun jurnal publikasi yang tersedia dan dapat digunakan untuk merujuk pada metode, teknologi, atau pendekatan terbaik dalam suatu bidang tertentu. Ini membantu dalam menganalisis perbedaan antara satu kajian dengan kajian lainnya, digunakan sebagai pendukung penelitian, referensi, acuan, atau pedoman untuk penelitian mendatang dan bahan pertimbangan dalam penelitian. Beberapa kajian dijadikan tambahan informasi agar dapat memberikan pengetahuan lebih melalui metode metode yang digunakan pada penelitian tersebut sebagai bahan penelitian.

Tawsifur Rahman bersama 9 anggota timnya melakukan penelitian untuk mengembangkan system diagnosis berbantuan komputer (CAD) untuk mendeteksi Tuberkulosis dari X-ray dada dengan menggunakan 9 arsitektur pada CNN. Penelitian ini menggunakan berbagai dataset yang bersumber dari NLM, Belarus, NIAID, RSNA dengan jumlah data mencapai 7000 gambar yang terdiri dari 3500 normal dan 3500 tuberkulosis, data gambar ini diubah ukurannya menjadi 224x224 piksel. Penggunaan *Stochastic Gradient Descent (SGD) Optimizer*, *learning rate* sebesar 0.001, ukuran *batch* 32, dropout rate sebesar 0.2, dan *epoch* yang diterapkan sebanyak 15 untuk klasifikasi dan 50 untuk segmentasi. DenseNet201 menunjukkan hasil evaluasi terbaik dalam deteksi Tuberkulosis (TB) ketika digunakan pada citra paru-paru yang telah disegmentasi, dengan akurasi 98,6%, presisi 98,57%, recall 98,56%, F1-score

98,56%, dan spesifisitas 98,54%. Visualisasi Score-CAM dan t-SNE mengonfirmasi bahwa DenseNet201 memfokuskan prediksi pada area paru-paru, meningkatkan keandalan diagnosis. Meskipun secara komputasi lebih lambat, kinerja superior DenseNet201 menjadikannya model paling efektif dalam penelitian ini untuk deteksi TB berbasis CNN.(Rahman et al., 2020)

Pada penelitian yang dilakukan oleh Razief Moch Diar, R. Yunendah Nur Fu'Adah, dan Koredianto Usman menggunakan Convolutional Neural Network (CNN) untuk mengklasifikasi penyakit paru-paru berbasis citra X-ray. Arsitektur MobileNet digunakan untuk mendeteksi dan mengklasifikasikan kondisi paru-paru ke dalam empat kelas yaitu Viral Pneumonia, Coronavirus Disease-19 (Covid-19), Normal dan Tuberculosis. Dataset yang digunakannya berasal dari Kaggle yang terdiri dari 15.853 citra X-ray paru-paru oleh Tawsifur Rahman. Penelitian ini menggunakan dua jenis preprocessing, yaitu CLAHE, dan Gaussian filter, serta penerapan *optimizer Stochastic Gradient Descent (SGD)*, dan *Adaptive moment (Adam)*. Pada *epoch* 50 menunjukkan kombinasi terbaik Adam dan CLAHE dan menghasilkan nilai akurasi sebesar 94,687% dan loss sebesar 0,148. Selain itu juga diperoleh hasil dari performansi sistem berupa presisi 95%, recall 93%, dan F-1 score sebesar 94%.(Diar et al., 2022)

Vinayak Sharma, Nillmani, Sachin Kumar Gupta, dan Kaushal Kumar Shukla melakukan penelitian terkait deteksi tuberkulosis menggunakan model CNN dengan arsitektur U-Net untuk segmentasi dan arsitektur Xception terdiri tiga fase (*entry flow*, *middle flow*, *exit flow*) untuk klasifikasi. Pada setiap flow memiliki lapisan konvolusi, diikuti aktivasi ReLu dan *MaxPooling*. Input ke *entry flow* beresolusi 224x224 dan pengklasifikasian terakhir dari *exit flow* merupakan lapisan *logistic regression*. Model dilatih selama 100 *epoch* dengan *learning rate* sebesar 0.001 dan *dropout rate* 0.25. Fungsi loss yang digunakan adalah *categorical cross-entropy* (LCCE). Penelitian ini menggunakan dataset klasifikasi “National Institute of Allergy and Infectious Diseases (NIAID) TB portal program dataset”, namun hanya menggunakan 1400 data (700 TB dan 700 normal) dari 4200 data, serta kombinasi dataset “Montgomery County” dan “Shenzhen Hospital” dengan total 704 data. Model U-Net menunjukkan

performa tinggi dengan nilai akurasi sebesar 96,35%, Jaccard Index (IoU) sebesar 90,38%, Dice Coefficient sebesar 94,88%, dan AUC mencapai 0,99. Untuk tugas klasifikasi menggunakan arsitektur Xception, diperoleh akurasi sebesar 99,29%, precision sebesar 99,30%, recall sebesar 98,29%, F1-score sebesar 99,29%, dan AUC sebesar 0,999. Penelitian ini juga menerapkan visualisasi menggunakan Grad-CAM.(Sharma et al., 2024)

Menurut Bondan Surya Nusantara dan Mutaqin Akbar pada penelitiannya menggunakan Multi-Scale CNN yang terdiri dari 3 lapisan konvolusi berukuran 3x3, 3 lapisan penggabungan (Maxpool) berukuran 2x2, dan 1 lapisan Fully Connected dengan aktivasi *softmax*, penggunaan algoritma *Adam Optimizer*, dan *Cross-entropy* sebagai penghitung fungsi loss, serta penggunaan 128 filter pada setiap lapisan. Penelitian ini berhasil mendapatkan akurasi terbaik 99,29% nilai loss 0,02 di skenario pertama dan 97,63% nilai loss 0,10 pada skenario kedua dengan total 20 epoch. Data yang digunakan berupa citra X-ray thorax yang tersedia pada platform Kaggle yang terdiri dari 1400 data dengan 2 kelas normal dan tuberculosis.(Nusantara and Akbar, 2024)

Penelitian tentang pengembangan CNN untuk deteksi TB berbasis sinar-X oleh Edna Chebet Too, David Gitonga Mwathi, Lucy Kawira Gitonga, Pauline Mwaka, dan Saif Kinyori dilakukan menggunakan arsitektur utama DenseNet121 yang dipangkas (*pruned*) yang disebut *Pruned Dense Convolutional Neural Network* (PDenseNet). Dataset yang digunakan terdapat 4200 gambar terdiri dari kelas tuberculosis (700 data) dan normal (3500 data). Penelitian ini juga menggunakan dataset lapangan yang dikumpulkan dari rumah sakit level 4-5 di daerah Embu, Tharaka-Nithi, dan Meru, Kenya. Data-data ini diubah ukurannya menjadi 150x150 piksel sebelum digunakan *training*. Penggunaan *Stochastic Gradient Descent (SGD) Optimizer* dengan jumlah epoch 50, *learning rate* 0,01, ukuran *batch* 32. Penelitian ini berhasil mendapatkan akurasi, presisi, recall, dan F1-score masing-masing sebesar 99%. Selain itu, ukuran model berhasil dikurangi secara signifikan dari 84,9 MB (versi asli DenseNet121) menjadi hanya 29 MB, dengan tingkat reduksi mencapai 65,8%.(Too et al., 2024)

Berikut merupakan ringkasan dari beberapa kajian tersebut yang termasuk dalam kajian pendamping dari penelitian sebelumnya yang dijadikan sebagai rujukan bagi penelitian ini, antara lain:

Tabel 2. 1 State of the art

No	Judul Penelitian	Metode / Model	Dataset	Hasil	Catatan
1.	Reliable Tuberculosis Detection Using Chest X-Ray With Deep Learning, Segmentation and Visualization (Rahman et al., 2020)	CNN dengan 9 arsitektur (ResNet18, ResNet50, ResNet101, ChexNet, InceptionV3, Vgg19, DenseNet20, SqueezeNet, and MobileNet)	“Chest X-ray Dataset for Tuberculosis Segmentation” 704 gambar untuk segmentasi. “Tuberculosis (TB) Chest X-ray Database” 7000 gambar untuk klasifikasi	Arsitektur terbaik: DenseNet201 Presisi: 98,57% <i>Recall</i> : 98,56% <i>F1-score</i> : 98,56% Akurasi: 98,6% Spesifisitas: 98,54%	• Komputasi berat akibat kedalaman model, sehingga dinilai kurang efisien • Score-CAM dan t-SNE untuk visualisasi. • Keterbatasan dalam evaluasi lintas Dataset, tanpa bukti validasi data baru
2.	Klasifikasi Penyakit Paru-Paru Berbasis Pengolahan Citra X	MobileNet, Preprocessing menggunakan CLAHE dan Gaussian Filter	“COVID-19 Radiography Database” terdiri 15.153 gambar	Akurasi: 94,687% Loss: 0,148 <i>Precision</i> : 95% <i>Recall</i> : 93%	• Tidak dilakukan segmentasi sehingga klasifikasi tidak fokus ke paru paru


	Ray Menggunakan Convolutional Neural Network (Diar et al., 2022)	Training menggunakan <i>SGD</i> dan <i>Adam</i> Epoch: 50	ditambah dengan 700 gambar tuberkulosis, sehingga total 15.853 gambar	<i>F1-score</i> : 94%	• Tidak fokus pada tuberkulosis • Belum adanya transparansi model berbasis XAI
3.	Deep learning models for tuberculosis detection and infected region visualization in chest X-ray images (Sharma et al., 2024)	Segmentasi menggunakan model U-Net, Klasifikasi menggunakan model Deep Learning Xception	“Chest X-ray Dataset for Tuberculosis Segmentation” 704 gambar untuk segmentasi. “Tuberculosis (TB) Chest X-ray Database” 1400 gambar untuk klasifikasi	Segmentasi UNet: Accuracy: 96.35% Jaccard Index (IoU): 90.38% Dice Coefficient: 94.88% AUC: 0.99 Klasifikasi Xception: Accuracy: 99.29% Precision: 99.30% Recall: 99.29% F1-score: 99.29% AUC: 0.999	• Terdapat transparansi model berbasis XAI Grad-CAM • Pelatihan model membutuhkan sumber daya komputasi yang sangat besar

4.	Klasifikasi Penyakit Tuberculosis Berdasarkan Citra Rontgen Thorax Menggunakan Multi-Scale Convolutional Neural Network (Nusantara and Akbar, 2024)	Deep Learning berbasis Multi-Scale CNN. Arsitektur: <i>MobileNet</i> Optimizer: Adam. Epoch: 20.	“Tuberculosis (TB) Chest X-ray Database” dengan total 1400 gambar yang dipakai	Nilai akurasi sebesar 99,29% pada skenario 1 dan 97,67% pada skenario 2.	• Tidak dilakukan segmentasi sehingga klasifikasi tidak fokus ke paru paru • Belum adanya transparansi model berbasis XAI
5.	An X-ray image-based pruned dense convolution neural network for tuberculosis detection	Pruned Convolutional Neural Network berbasis DenseNet121 (PDenseNet)	“Tuberculosis (TB) Chest X-ray Database” terdiri dari 4200 gambar dan data testing menggunakan data private (lapangan)	Akurasi: 99% Presisi: 99% Recall: 99% F1-score: 99% Ukuran Model: Berkurang dari 84.9 MB (DenseNet121 asli) menjadi 29 MB Reduction Rate: 65,8%	• Belum adanya transparansi model berbasis XAI • Tanpa segmentasi gambar • Ukuran gambar rendah (150x150) • Potensi bias karena tidak ada

	(Too et al., 2024)				penanganan label imbalance
6.	Klasifikasi Tuberkulosis Berbasis Citra X-ray Dada dengan Explainable AI Menggunakan DenseNet121 dan Grad-CAM (Penelitian Saat Ini)	Segmentasi dengan U-Net Klasifikasi dengan DenseNet121 Implementasi XAI Grad-CAM	“Chest X-ray Dataset for Tuberculosis Segmentation” 704 gambar untuk segmentasi. “Tuberculosis (TB) Chest X-ray Database” 1400 gambar untuk klasifikasi	Akurasi: 94.29% Presisi: 94.35% Recall: 94.29% F1-score: 94,28% AUC: 0,9751 Dice Coefficient: 94%	• Penggunaan XAI sebagai transparansi model • Pelatihan model efisien • Klasifikasi dengan DenseNet121 pada dataset khusus TBC • Dilakukan Segmentasi dengan U-Net • Menggunakan ukuran gambar (224x224)

2. 2 Tinjauan Pustaka

2. 2. 1 Tuberkulosis



Gambar 2. 1 Tuberkulosis (Vitrosens, 2023)

Tuberkulosis (TBC) adalah penyakit infeksi menular yang disebabkan oleh bakteri *Mycobacterium tuberculosis*, yang terutama menyerang paru-paru, meskipun juga dapat mengenai organ lain seperti otak, tulang, dan ginjal (World Health Organization, 2022). *Mycobacterium tuberculosis* merupakan patogen paling sukses menginfeksi paru-paru yang menyebar melalui percikan dahak (doplek) dari pengidap TBC aktif saat batuk, berbicara, atau bersin, sehingga kontak langsung dengan pengidap TBC meningkatkan resiko penularan (Nusantara and Akbar, 2024; Sapto et al., 2021). Tuberkulosis merupakan masalah kesehatan global dan salah satu penyebab kematian tertinggi di seluruh dunia setelah HIV/AIDS (Aviana et al., 2021). Sejarah TBC dapat ditelusuri sejak ribuan tahun lalu, terbukti dari infeksi yang ditemukan pada mumi Mesir kuno. Pada abad ke-19, TBC dikenal dengan istilah "consumption" di Eropa, menggambarkan kondisi penderita yang mengalami wasting.

Dalam tubuh manusia, infeksi TBC dimulai ketika droplet infeksius mencapai alveoli paru dan ditangkap oleh makrofag. Pada sistem imun yang kuat, bakteri terperangkap dalam granuloma, menghasilkan TBC laten tanpa gejala. Sebaliknya, pada TBC aktif bakteri berkembang biak, merusak jaringan paru, dan dapat menyebar ke organ lain (Liebenberg et al., 2022). Deteksi dan diagnosis penyakit ini seringkali dilakukan melalui pemeriksaan X-ray paru paru (Nusantara and Akbar, 2024), dengan mengombinasikan pemeriksaan

klinis, dan laboratorium. Pemeriksaan sputum (mikroskopi dan GeneXpert) menjadi standar utama untuk diagnosis TBC aktif, sedangkan uji tuberkulin dan IGRA digunakan untuk mendeteksi infeksi laten. Terdapat beberapa jenis TBC yang umum dikenal antara lain:

1. TBC Paru (*Pulmonary Tuberculosis*): jenis ini paling umum dari TBC yang menyerang paru paru dan dapat menular melalui udara saat penderita batuk dan bersin.(Zhou et al., 2022)
2. TBC Ekstra Paru (*Extrapulmonary Tuberculosis*): jenis ini menyerang organ lain diluar paru-paru seperti tulang, sendi, ginjal, sistem syaraf, kulit dan organ lainnya. Jenis ini umumnya tidak mudah menular.
3. TBC Laten (*Latent Tuberculosis Infection*): bakteri *Mycobacterium tuberculosis* telah berada dalam tubuh dalam keadaan tidak aktif, sehingga tidak menimbulkan gejala dan tidak menular, namun dapat menjadi TBC aktif apabila sistem kekebalan tubuh penderita melemah.
4. TBC Aktif (*Active Tuberculosis Disease*): bakteri telah beraktivitas dan menyebabkan gejala dan penularan dapat terjadi jika terjadi di paru paru atau saluran pernafasan. Jenis ini memerlukan pengobatan segera dengan regimen antibiotic.
5. TBC Resisten Obat (*Drug-Resistant Tuberculosis*): Jenis ini tidak bereaksi terhadap beberapa jenis obat anti-TB standar seperti MDR-TB (Multidrug-Resistant TB) yang kebal terhadap isoniazid dan rifampisin, XDR-TB (Extensively Drug-Resistant TB) yang kebal terhadap lebih banyak jenis obat. TBC jenis ini membutuhkan penanganan yang lebih kompleks dan terapi yang lebih lama.(Aviana et al., 2021)

Pemeriksaan rontgen dada berperan penting dalam mendeteksi karakteristik TBC seperti infiltrat dan kavitas, meskipun hasil radiologi perlu dikonfirmasi melalui uji mikrobiologi untuk membedakannya dari penyakit paru lainnya. Untuk membantu diagnosis, sistem otomatisasi berbasis kecerdasan buatan (AI) atau *machine learning* (ML), seperti Convolutional Neural Network (CNN), sedang banyak dikembangkan untuk mendiagnosis

dan mengklasifikasi penyakit tuberkulosis berdasarkan citra X-ray(Leonard et al., 2024).

2. 2. 2 Citra X-Ray Dada



Gambar 2. 2 Citra X-ray Dada

Citra X-ray dada adalah gambaran visual dari bagian dalam tubuh manusia, khususnya area dada, yang dihasilkan melalui pemanfaatan sinar-X. Proses ini melibatkan pemancaran radiasi elektromagnetik dalam spektrum sinar-X ke tubuh, di mana jaringan tubuh dengan densitas berbeda (seperti tulang, organ, dan udara) menyerap sinar dengan tingkat yang bervariasi, menghasilkan gambar hitam putih. Tulang rusuk dan tulang belakang memberikan gambar putih karena menyerap lebih banyak sinar, sementara udara dalam paru-paru tampak gelap. Citra X-ray ini direpresentasikan sebagai citra digital berbentuk matriks dua dimensi dengan ukuran $M \times N$, di mana M adalah jumlah baris dan N adalah jumlah kolom. Setiap elemen dalam matriks, disebut piksel, menyimpan informasi densitas jaringan tubuh (Wahyuningrum et al., 2023).

Citra dada atau X-ray adalah salah satu pemeriksaan pencitraan yang paling sering digunakan di dunia karena murah, tersedia luas, dan mampu mendeteksi berbagai kondisi jantung, paru-paru, tulang dada, serta struktur lainnya dengan dosis radiasi rendah. Pemeriksaan ini sangat berguna dalam dunia medis untuk mendeteksi masalah kesehatan seperti infeksi, tumor, atau penyakit kronis. Namun, interpretasi citra dada seringkali sulit, yang dapat menyebabkan kesalahan diagnosis dan berpotensi memicu tuntutan hukum

malpraktik medis (Gefter et al., 2023). Untuk mengatasi tantangan ini, diagnosis citra dada telah menjadi bidang penelitian yang berkembang pesat dengan banyak metode berbasis AI (Yan and Pei, 2022), seperti penerapan XAI (Explainable Artificial Intelligence) contohnya LIME, SHAP, dan Grad-CAM yang membantu mengatasi masalah "kotak hitam" (black box) pada model AI dalam pengambilan keputusan dan diagnosa (Bhandari et al., 2022b).

2. 2. 3 Machine Learning

Machine Learning merupakan cabang dari kecerdasan buatan yang mempelajari bagaimana sistem dapat belajar dari data. Dengan menggunakan algoritma yang dilatih dengan data berlabel atau tanpa label, pembelajaran mesin memungkinkan sistem untuk membuat prediksi dan mendukung keputusan otomatis berdasarkan pola-pola yang ditemukan dalam data. ML mencakup empat kategori utama yaitu

- **Supervised Learning** mempelajari fungsi pemetaan input-output berdasarkan pasangan contoh dengan algoritma seperti Decision Tree, Naive Bayes, Support Vector Machine (SVM) dan Convolutional Neural Network (CNN)
- **Unsupervised Learning** bekerja tanpa data berlabel, menggunakan algoritma seperti Principal Component Analysis (PCA) untuk reduksi dimensi dan K-Means Clustering untuk pengelompokan data
- **Semi-Supervised Learning** menggabungkan data berlabel dan tak berlabel
- **Reinforcement Learning** memungkinkan agen perangkat lunak belajar mengambil tindakan di lingkungan untuk memaksimalkan penghargaan kumulatif.

Teknik pendukung seperti Instance-Based Learning, Ensemble Learning (termasuk Boosting dan Bagging), membantu meningkatkan akurasi model. Dengan algoritma yang terus disempurnakan, pembelajaran mesin mampu mengenali pola dan memberikan wawasan dari data yang kompleks.

Selain itu, model canggih seperti Neural Networks, yang dirancang untuk mengenali hubungan dalam data dengan cara yang meniru cara kerja otak manusia, memainkan peran penting dalam berbagai aplikasi, termasuk dalam sistem prediksi dan otomatisasi berbasis kecerdasan buatan.(Mahesh, 2020)

Dalam penelitian tentang deteksi gambar, Machine Learning memainkan peran penting dengan penggunaan metode seperti Support Vector Machine (SVM) untuk klasifikasi sederhana hingga jaringan saraf tiruan untuk deteksi yang lebih kompleks. Model ini memanfaatkan berbagai data input, seperti citra X-ray dan CT-Scan, serta informasi kesehatan pasien untuk menghasilkan klasifikasi yang akurat (Kharis et al., 2024).

2. 2. 4 Deep Learning

Deep learning adalah cabang dari machine learning yang telah merevolusi pengembangan kecerdasan buatan melalui penggunaan jaringan saraf tiruan berlapis (deep neural networks) untuk memproses data dan membangun model komputasi kompleks. Metode ini telah menunjukkan keberhasilan luar biasa dalam berbagai bidang, seperti pengolahan suara, visi komputer, pengolahan bahasa alami, serta aplikasi di bidang medis (Dong, Wang, & Abbas, 2021). Dalam konteks analisis citra medis, arsitektur seperti Convolutional Neural Network (CNN) secara luas digunakan karena kemampuannya dalam mengekstraksi fitur visual dari gambar medis seperti X-ray dan CT scan. Selain CNN, model seperti U-Net terbukti efektif untuk segmentasi struktur anatomi pada citra medis karena arsitekturnya memungkinkan penggabungan informasi spasial dari berbagai tingkat resolusi (Ronneberger et al., 2015).

Salah satu aplikasi penting dari deep learning dalam dunia medis adalah dalam deteksi penyakit paru, termasuk Tuberkulosis (TBC). Model CNN yang dilatih dengan dataset X-ray dada telah mencapai performa tinggi dalam mengklasifikasikan citra pasien TBC, bahkan mendekati tingkat akurasi ahli radiologi (Lakhani & Sundaram, 2017). Selain klasifikasi, teknik segmentasi

berbasis deep learning juga digunakan untuk menyoroti area paru yang terdampak, memberikan gambaran visual yang memperkuat interpretasi diagnosis. Studi lebih lanjut menunjukkan bahwa deep learning dapat diintegrasikan dengan pendekatan multimodal seperti CLIP, yang menggabungkan data visual dan teks untuk menghasilkan analisis diagnostik yang lebih kaya (Radford et al., 2021). Dengan dukungan dataset publik dan komputasi modern, pendekatan ini berpotensi menjadi solusi skrining massal yang efisien di wilayah dengan keterbatasan sumber daya medis.

2. 2. 5 Klasifikasi

Klasifikasi merupakan salah satu tugas utama dalam pembelajaran mesin yang termasuk dalam kategori supervised learning, di mana tujuan utamanya adalah memetakan input ke dalam label atau kategori tertentu berdasarkan pola dari data latih yang telah berlabel. Proses ini memungkinkan mesin atau sistem untuk mempelajari karakteristik dari masing-masing kelas, sehingga dapat memprediksi kelas dari data baru yang belum diketahui. Klasifikasi memiliki peran penting dalam berbagai bidang seperti pengenalan suara, pemrosesan teks, dan terutama dalam pengolahan citra digital (Alpaydin, 2020). Model-model yang digunakan dalam klasifikasi dapat berupa algoritma klasik seperti decision tree dan support vector machine (SVM), maupun model yang lebih kompleks seperti neural networks dan deep learning.

Dalam bidang pengolahan citra digital, klasifikasi bekerja dengan mengidentifikasi pola visual dalam gambar untuk kemudian menentukan ke kelas mana gambar tersebut termasuk. Proses ini melibatkan tahapan seperti pra-pemrosesan citra, ekstraksi fitur, dan pelatihan model klasifikasi. Dengan kemajuan deep learning, khususnya penggunaan Convolutional Neural Networks (CNN), klasifikasi citra telah mencapai tingkat akurasi yang sangat tinggi dalam berbagai aplikasi, termasuk deteksi penyakit pada citra medis (Litjens et al., 2017). CNN mampu secara otomatis mengekstraksi fitur relevan dari gambar tanpa memerlukan proses ekstraksi fitur manual, sehingga

mempercepat dan meningkatkan efisiensi sistem klasifikasi. Penggunaan klasifikasi dalam citra medis, misalnya, telah terbukti efektif dalam membedakan antara citra normal dan yang mengandung kelainan seperti Tuberkulosis atau kanker.

2. 2. 6 Segmentasi Citra


Segmentasi citra adalah proses membagi citra digital menjadi beberapa segmen atau wilayah untuk menyederhanakan representasi visual agar lebih bermakna dan mudah dianalisis. Proses ini melibatkan pemisahan objek yang diinginkan (foreground) dari latar belakang (background), serta mempartisi gambar menjadi wilayah-wilayah dengan ciri serupa untuk mempermudah analisis dan aplikasi lebih lanjut (Wahyuningrum et al., 2023). Dalam konteks medis, segmentasi membantu memisahkan area spesifik seperti organ atau jaringan yang relevan untuk diagnosis, perencanaan pengobatan, dan pelacakan perkembangan penyakit. Proses ini mencakup langkah-langkah seperti preprocessing (misalnya, noise reduction atau normalisasi intensitas), identifikasi region of interest (ROI), dan penerapan metode segmentasi seperti thresholding, edge detection, region-based segmentation, atau deep learning-based segmentation menggunakan model modern seperti U-Net. Metode lain seperti clustering dengan algoritma K-means dan Fuzzy C-Means (FCM) juga efektif dalam memisahkan objek pada citra medis, termasuk dalam dataset CT scan kanker paru-paru (Ridlo Hanifudin Tahier et al., 2023). Contohnya, pada X-ray dada, segmentasi memisahkan area organ dari tulang atau jaringan lain untuk analisis lebih mendalam.

Segmentasi citra memberikan manfaat signifikan dalam meningkatkan efisiensi, akurasi, dan objektivitas dalam analisis citra medis, sekaligus mengurangi bias manusia dan kesalahan diagnosis. Selain diagnosis medis, segmentasi juga digunakan dalam berbagai aplikasi seperti deteksi objek (jalan, tanaman, kendaraan), pengenalan wajah, dan sidik jari, menjadikannya teknologi serbaguna di berbagai bidang (Ridlo Hanifudin Tahier et al., 2023).

Aplikasi teknologi modern seperti deep learning dan transfer learning semakin memperkuat akurasi segmentasi, sementara explainable AI (XAI) membantu menjelaskan hasil segmentasi kepada profesional medis. Meski demikian, tantangan seperti keterbatasan data, variasi kualitas citra, dan kebutuhan akan keakuratan tinggi tetap menjadi kendala yang harus diatasi. Dalam penelitian ini, segmentasi citra X-ray dada dapat digunakan untuk memisahkan area dada dan menghasilkan klasifikasi pada citra X-ray untuk mendukung tenaga medis

2. 2. 7 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) merupakan salah satu jenis jaringan saraf tiruan yang paling banyak digunakan dalam analisis citra, terutama dalam bidang visi komputer dan medis. CNN dirancang untuk secara otomatis mengekstraksi fitur spasial dari gambar melalui proses konvolusi, di mana filter atau kernel kecil bergerak melintasi gambar untuk mendeteksi pola-pola penting seperti tepi, tekstur, dan bentuk (Gu et al., 2018; Li et al., 2022). Komponen utama dalam CNN meliputi convolutional layer, activation function seperti ReLU, pooling layer untuk mereduksi dimensi, dan fully connected layer untuk klasifikasi akhir (Cai, 2024). Dalam konteks citra medis seperti X-ray dada, CNN sangat efektif dalam mengidentifikasi karakteristik visual yang relevan untuk mendeteksi penyakit seperti Tuberkulosis atau pneumonia, karena kemampuannya dalam mengenali pola yang sulit dibedakan oleh pengamat manusia (Dendi Maysanjaya, 2020).




Gambar 2. 3 Model CNN (Kristian Wilianto, 2021)

Untuk meningkatkan kinerja model CNN, khususnya dalam kondisi keterbatasan data berlabel seperti yang sering ditemukan dalam dataset medis, pendekatan transfer learning menjadi sangat penting. Dalam praktiknya, transfer learning diterapkan dengan memanfaatkan model CNN yang telah dilatih pada dataset besar seperti ImageNet, lalu disesuaikan (fine-tuned) pada dataset spesifik, misalnya gambar X-ray untuk klasifikasi penyakit paru. CNN juga dapat diadaptasi untuk menangani sinyal yang kompleks dengan menerapkan variasi arsitektur seperti dilated convolution, yang meningkatkan jangkauan temporal tanpa menambah kompleksitas model, serta multi-scale convolution, yang berguna untuk mengatasi ketidakstabilan sinyal non-stasioner. Keunggulan CNN dalam mendeteksi pola mikro dari data mentah menjadikannya sangat efektif dan efisien (Balam et al., 2021; Obaidan et al., 2024; Ramzan et al., 2024). Strategi ini tidak hanya menghemat waktu pelatihan, tetapi juga meningkatkan akurasi model dalam mendeteksi fitur penting dari data medis yang kompleks (Shin et al., 2021).

2. 2. 8 DenseNet-121

DenseNet121 merupakan salah satu arsitektur dalam model Convolutional Neural Network (CNN) dimana metode Deep Learning yang umum dipakai untuk deteksi objek dan klasifikasi gambar. Model DenseNet pertama kali diperkenalkan sekitar tahun 2016/2017 (Wijaya Kusuma et al., 2023). Konsep utama DenseNet berbeda dari pendekatan konvensional yang hanya menambah lapisan atau melebarkan jaringan untuk meningkatkan performa. Sebaliknya, DenseNet mengusung konsep koneksi padat (*dense connectivity*) di mana setiap lapisan menerima input dari seluruh lapisan sebelumnya melalui struktur yang disebut *Dense Block*. Pendekatan ini memungkinkan aliran informasi yang optimal antar lapisan dan meningkatkan efisiensi penggunaan ulang fitur (*feature reuse*), sehingga secara signifikan mengurangi jumlah parameter dan membantu mengatasi permasalahan


vanishing gradient yang umum terjadi pada jaringan dalam (*deep network*)(Liu and Huang, 2020).



Gambar 2. 4 Arsitektur DenseNet121 (Wijaya Kusuma et al., 2023)

Salah satu keunggulan signifikan DenseNet121 adalah jumlah parameternya yang jauh lebih sedikit sekitar 8 juta parameter, dibandingkan dengan model seperti VGG16 yang memiliki 138 juta parameter dengan performa klasifikasi yang sama, serta strukturnya dianggap cocok untuk mempertahankan fitur-fitur penting(Wijaya Kusuma et al., 2023). Selain itu, dalam studi deteksi tuberkulosis menggunakan citra X-ray dada, DenseNet121 menunjukkan performa klasifikasi terbaik di antara enam model CNN populer lainnya dengan akurasi tertinggi (0,835), serta nilai *true positive* (TP) dan *true negative* (TN) tertinggi dan *false positive* (FP) serta *false negative* (FN) terendah(Liu and Huang, 2020). Keunggulan ini juga menginspirasi pengembangan arsitektur lanjutan seperti Dense U-Net dan U-Net++, yang banyak digunakan pada tugas segmentasi citra medis(Liu et al., 2022; Yousef et al., 2023). DenseNet121 juga digunakan sebagai arsitektur dasar dalam MetaChexNet untuk memprediksi 14 label patologi dan metadata pasien (posisi, jenis kelamin, usia) serta klasifikasi deteksi TB (Gozes and Greenspan, 2019). Dengan kemampuan mempertahankan fitur penting, efisiensi parameter, dan akurasi tinggi, DenseNet121 dinilai sangat potensial untuk diimplementasikan dalam sistem deteksi penyakit berbasis citra medis.


Dense Block



Gambar 2. 5 Dense Block (Wijaya Kusuma et al., 2023)

2. 2. 9 U-Net

U-Net merupakan salah satu arsitektur *Convolutional Neural Network* (CNN) yang secara luas diakui sebagai model unggulan dalam menyelesaikan tugas segmentasi gambar. Dikembangkan secara khusus untuk segmentasi citra biomedis (*biomedical image segmentation*) yang seringkali dihadapkan pada keterbatasan jumlah data pelatihan oleh Olaf Ronneberger dan timnya pada tahun 2015(Ataş, 2023; Yousef et al., 2023). Memiliki kemampuan beroperasi pada jumlah dataset terbatas dengan performa tinggi dan hasil yang akurat membuat popularitas U-Net tinggi(Yousef et al., 2023). Arsitekturnya mengadopsi bentuk simetris encoder-decoder yang terdiri dari dua jalur utama, yakni *contraction path* (encoder) untuk mengekstraksi fitur kontekstual melalui konvolusi dan *downsampling*, serta *expansion path* (decoder) untuk merekonstruksi informasi spasial dengan *upsampling* dan dekonvolusi(Ataş, 2023; Shim et al., 2022; Yousef et al., 2023).



Gambar 2. 6 Arsitektur U-Net (Rahman et al., 2020)

Salah satu kekuatan utama dari U-Net terletak pada penggunaan koneksi pintas (*skip connections*) dengan menghubungkan lapisan encoder dan decoder yang sepadan. Mekanisme koneksi ini membantu mempertahankan detail spasial penting yang hilang selama proses downsampling, sehingga hasil segmentasi menjadi lebih presisi (Shim et al., 2022). Kemampuan adaptif dari arsitektur ini menjadikannya fondasi bagi banyak varian yang dikembangkan untuk meningkatkan performa atau menyesuaikan dengan jenis data tertentu. Beberapa varian penting dari U-Net telah dikembangkan untuk meningkatkan performa segmentasi, seperti 3D U-Net untuk segmentasi volumetrik, ResU-Net dan R2U-Net yang mengatasi *vanishing gradient* dengan koneksi residual dan blok rekuren, serta Attention U-Net (AU-Net) yang menggunakan mekanisme atensi untuk menonjolkan fitur penting (Shim et al., 2022; Yousef et al., 2023).

Varian lain seperti Dense U-Net dan U-Net++ menerapkan *dense connectivity* untuk memperkuat aliran informasi antara encoder dan decoder. Versi yang lebih kompleks seperti AR2U-Net dan U-Net 3+ menyempurnakan arsitektur untuk segmentasi anatomi yang lebih akurat. Selain itu, integrasi dengan Generative Adversarial Networks (GAN) menghasilkan Adversarial U-Net, yang digunakan dalam augmentasi data dan deteksi citra otak. Berbagai studi menunjukkan bahwa varian-varian ini unggul dalam metrik seperti *Dice Coefficient*, *Accuracy*, *Sensitivity*, dan *Specificity* (Yousef et al., 2023). Model U-Net menunjukkan performa unggul dalam segmentasi citra medis seperti paru-paru, otak, jantung, dan organ internal, serta diaplikasikan pada citra satelit dan kendaraan otonom. Evaluasinya menggunakan metrik seperti *Dice Coefficient* dan *Jaccard Index* (Liu et al., 2022). Dengan struktur efisien dan fleksibilitasnya menjadikan U-Net pilihan utama dalam segmentasi hingga kini.

2. 2. 10 Explainable Artificial Intelligence (XAI)

Explainable Artificial Intelligence (XAI) atau Kecerdasan Buatan yang dapat dijelaskan adalah bidang penting yang muncul untuk mengatasi masalah model AI yang sulit dipahami (black box)(Bhandari et al., 2022b). Dalam dunia nyata, terutama di bidang kesehatan, para pengambil keputusan seperti dokter memiliki keterbatasan waktu, informasi, dan kemampuan dalam memahami proses kompleks(Gipiškis et al., 2024; Stahlschmidt et al., 2022). Karena itu, sangat penting agar AI bisa memberikan alasan yang jelas di balik keputusan atau prediksinya. Tanpa penjelasan yang masuk akal pengguna terutama tenaga medis dan pasien bisa kehilangan kepercayaan terhadap teknologi tersebut.(Alfina et al., 2024)

XAI bertujuan membuat sistem AI menjadi lebih transparan dan mudah dimengerti manusia. Ini membantu pengguna untuk lebih percaya, memahami cara kerja model, menemukan potensi bias, memenuhi aturan regulasi, dan bahkan memperbaiki model AI yang digunakan(Alfina et al., 2024; Gading Rayya Samita et al., 2024). Salah satu cara yang digunakan XAI adalah dengan teknik post-hoc, yaitu metode penjelasan yang diterapkan setelah model selesai dilatih. Terdapat banyak metode post-hoc XAI, tiga terpopuler diantaranya yaitu:

1. LIME (Local Interpretable Model-agnostic Explanations)

LIME merupakan model agnostic yang menjelaskan satu prediksi secara local dengan membuat model sederhana disekitar data yang ditunjuk. Ini cocok untuk berbagai tipe data (gambar, teks, tabular), dan menghasilkan penjelasan visual seperti highlight superpixels (Vimbi et al., 2024).

2. SHAP (SHapley Additive exPlanations)

SHAP merupakan model agnostic yang menghitung seberapa besar kontribusi setiap fitur terhadap hasil prediksi, baik secara lokal (per data) maupun global (keseluruhan model), ini sangat populer dengan 80% penggunaan XAI dalam analisis tabular dan juga dapat digunakan untuk gambar (Caterson et al., 2024; Gipiškis et al., 2024)

3. Grad-CAM (Gradient-Weighted Class Activation Mapping)

Grad-CAM merupakan pengembangan dari Class Activation Map (CAM) dengan menyoroti wilayah penting pada gambar dengan heatmap untuk membantu visualisasi pengaruh terhadap prediksi. Ini termasuk ke dalam model spesifik terutama untuk CNN dan bersifat lokal (Famiglioni et al., 2024; Nazir et al., 2024).

Meskipun teknik ini bisa sangat membantu, kadang penjelasannya perlu disesuaikan agar lebih mudah dimengerti terutama dalam konteks klinis (Famiglioni et al., 2024). XAI telah banyak digunakan, misalnya dalam mendeteksi COVID-19, pneumonia, dan TBC dari gambar rontgen dada (CXR), menganalisis fraktur tulang belakang dari X-ray, menilai glaukoma dari foto mata (fundus), melihat MRI otak, serta di luar medis seperti chatbot, mobil otonom, keuangan, dan keamanan siber (Gading Rayya Samita et al., 2024; Kovari, 2025).

2. 2. 11 Transfer Learning

Transfer Learning (TL) adalah teknik dalam pembelajaran mesin yang memanfaatkan pengetahuan yang diperoleh dari satu tugas atau domain untuk meningkatkan kinerja pada tugas atau domain lain yang terkait. Teknik ini sangat berguna ketika data berlabel untuk tugas target terbatas, memungkinkan model untuk memanfaatkan pengetahuan dari tugas terkait dengan data berlabel yang lebih banyak (Kim et al., 2022; Stahlschmidt et al., 2022). Dalam konteks analisis citra medis, transfer learning memainkan peran penting karena ketersediaan data yang telah dianotasi oleh ahli sangat terbatas dan mahal secara waktu maupun sumber daya. Model deep learning, seperti CNN, yang telah dilatih pada dataset besar dan umum seperti ImageNet, dapat digunakan kembali untuk mendeteksi penyakit dari citra medis dengan pelatihan tambahan yang minimal. Proses ini memungkinkan sistem untuk tetap mendapatkan performa yang baik meskipun hanya dilatih menggunakan dataset berskala kecil (Kim et al., 2022).

Transfer learning umumnya dilakukan dengan dua pendekatan utama, yaitu ekstraksi fitur dan fine-tuning. Pada ekstraksi fitur, lapisan awal dari model pretrained digunakan untuk mengekstrak representasi ciri dari data baru, kemudian hanya bagian akhir model yang dilatih ulang. Sementara itu, fine-tuning memungkinkan pelatihan kembali pada seluruh atau sebagian besar parameter model untuk menyesuaikan dengan domain target (Kim et al., 2022; Wolf et al., 2020). Dengan ini menunjukkan bahwa penggunaan transfer learning dalam klasifikasi citra medis, khususnya X-ray dada, secara signifikan meningkatkan performa model dalam mendeteksi kelainan seperti Tuberkulosis. Pendekatan ini tidak hanya mempercepat proses pelatihan, tetapi juga meningkatkan akurasi dan generalisasi model, menjadikannya strategi yang sangat efektif dalam pengembangan sistem diagnosis berbasis kecerdasan buatan.(Stahlschmidt et al., 2022)

2. 2. 12 Pre-Processing

Pre-processing adalah tahap awal dalam pengolahan data yang melibatkan pembersihan, transformasi, integrasi, dan pengurangan yang bertujuan untuk mempersiapkan data mentah agar lebih terstruktur, relevan, meningkatkan kualitas, konsisten, dan sesuai untuk analisis atau model pembelajaran mesin sehingga menghasilkan analisis yang lebih efektif dan akurat (GeeksforGeeks, 2024). Data mentah sering kali tidak sempurna, mengandung noise, nilai hilang, atau informasi yang tidak relevan. Dengan melakukan pre-processing, data menjadi lebih bersih dan dapat meningkatkan akurasi serta efisiensi analisis.

Pre-processing sangat penting karena kualitas data sangat memengaruhi performa model pembelajaran mesin. Data yang buruk dapat menyebabkan kesalahan prediksi, bias, atau performa yang tidak optimal. Selain itu, pre-processing memungkinkan konsistensi data dengan menyatukan format yang berbeda dan mengurangi elemen yang tidak relevan, yang pada akhirnya membuat proses analisis lebih efisien. Dalam banyak kasus, pre-processing

juga membantu mengatasi kendala teknis, seperti menghilangkan noise pada data citra atau menormalkan nilai pada data numerik untuk mempermudah analisis. Beberapa tahapan penting dalam Pre-processing untuk data gambar antara lain:

1. **Noise Reduction** Mengurangi gangguan visual seperti piksel acak yang dapat mengaburkan detail penting pada citra X-ray. Umumnya digunakan filter seperti *Gaussian Blur* untuk menghaluskan citra tanpa menghilangkan fitur tepi
2. **Normalisasi Intensitas** Menstandarkan nilai intensitas piksel ke dalam rentang tertentu, seperti $[0, 1]$, untuk menjaga kestabilan pelatihan model dan mempercepat konvergensi
3. **Resizing** Menyesuaikan ukuran citra menjadi dimensi tetap (misalnya 224×224 piksel) agar sesuai dengan input arsitektur CNN, serta untuk menyamakan resolusi antar data
4. **Konversi Grayscale ke RGB** Citra grayscale diduplikasi ke tiga kanal untuk menyesuaikan input model pretrained CNN yang dirancang menerima format RGB
5. **Peningkatan Kontras** Teknik seperti *CLAHE* digunakan untuk memperjelas struktur paru-paru dan memperkuat perbedaan lokal pada intensitas piksel
6. **Segmentasi Area Paru-paru** Memfokuskan analisis pada area paru-paru dengan menghilangkan bagian tubuh lain menggunakan metode segmentasi, seperti U-Net
7. **Augmentasi Data** Menambah variasi citra melalui rotasi, flipping, zoom, dan perubahan kecerahan untuk mencegah overfitting dan memperkuat generalisasi model
8. **Pembagian Dataset** Dataset dibagi menjadi pelatihan, validasi, dan pengujian untuk menjamin evaluasi model yang objektif dan tidak bias.

2. 2. 13 Python

Python merupakan bahasa pemrograman tingkat tinggi yang dirancang untuk mempermudah penulisan kode dengan sintaks sederhana dan mudah dipahami, oleh Guido van Rossum di Belanda pada tahun 1989 sebagai penerus bahasa pemrograman ABC. Ini digunakan dalam berbagai bidang seperti pengembangan web, analisis data, kecerdasan buatan, dan banyak lagi (Kadiyala and Kumar, 2017). Python salah satu alat penting dalam data science karena memiliki pustaka yang kuat seperti Pandas, NumPy, dan Scikit-learn yang memungkinkan untuk pengolahan data yang kompleks, pembuatan model pembelajaran mesin, dan visualisasi data dalam satu ekosistem yang terintegrasi. Bahasa pemrograman ini populer di kalangan akademisi dan masyarakat umum yang dapat digunakan untuk berbagai hal, seperti membuat game, aplikasi desktop atau web, statistik, Internet of Things (IoT), analisis, pemrosesan data, visualisasi data, dan membangun proyek-proyek AI. Untuk penerapan model dan algoritma pada penelitian ini memanfaatkan python sebagai bahasa pemrogramannya.

2. 2. 14 Kaggle


Kaggle adalah platform berbasis komunitas yang didirikan pada tahun 2010, yang menyediakan layanan bagi data scientist, peneliti, dan pengembang untuk berkolaborasi, berbagi dataset, serta membangun dan membandingkan model pembelajaran mesin (Kaggle, 2010). Melalui kompetisi berbasis data, pengguna dapat memecahkan masalah dunia nyata dan mengasah keterampilan mereka dalam analisis data dan machine learning. Selain itu, Kaggle menawarkan kursus pembelajaran serta akses gratis ke ribuan dataset publik dari berbagai domain, termasuk kesehatan, ekonomi, teknologi, dan gambar medis, yang dapat dimanfaatkan untuk keperluan penelitian maupun aplikasi komersial.

Fitur utama lainnya dari Kaggle adalah Kaggle Notebook (sebelumnya dikenal sebagai Kernels), yaitu lingkungan pemrograman berbasis browser

yang memungkinkan pengguna menulis dan menjalankan kode dalam Python atau R tanpa memerlukan instalasi perangkat lunak tambahan (Bojer and Meldgaard, 2021; Kaggle, 2010). Hal ini memudahkan eksperimen, eksplorasi data, dan pembuatan model secara langsung di platform. Selain itu, komunitas pengguna yang sangat aktif serta adanya kompetisi dengan hadiah uang tunai dari berbagai perusahaan membuat Kaggle menjadi pusat kolaborasi ilmiah dan perkembangan profesional yang penting dalam dunia data science dan machine learning.(Bojer and Meldgaard, 2021).

2. 2. 15 Confusion Matrix

Confusion matrix adalah alat yang sangat berguna yang memberikan rincian kinerja klasifikasi model dengan menunjukkan jumlah prediksi true positive, false positive, true negative, dan false negative (Singh et al., 2021). Ini memberikan wawasan tentang jenis kesalahan yang dibuat oleh model, yang dapat membantu memahami apakah model membingungkan satu kelas dengan kelas lainnya. Rumus untuk confusion matrixnya:



Gambar 2. 7 Confusion Matrix

- TP (True Positives): Jumlah prediksi yang benar untuk kelas positif. Merepresentasikan Pasien yang benar-benar terinfeksi dan diprediksi terinfeksi(Singh et al., 2021).

- TN (True Negatives)): Jumlah prediksi yang benar untuk kelas negatif. Merepresentasikan Pasien yang benar-benar tidak terinfeksi dan diprediksi tidak terinfeksi(Singh et al., 2021).
- FP (False Positives): Jumlah prediksi yang salah di mana model memprediksi positif, tetapi kelas sebenarnya adalah negatif. Merepresentasikan Pasien yang sebenarnya tidak terinfeksi tetapi diprediksi terinfeksi (Singh et al., 2021).
- FN (False Negatives): Jumlah prediksi yang salah di mana model memprediksi negatif, tetapi kelas sebenarnya adalah positif. Merepresentasikan Pasien yang terinfeksi tetapi diprediksi tidak terinfeksi (Singh et al., 2021).

Confusion matrixnya divisualisasikan dalam bentuk heatmap, yang membantu untuk mengidentifikasi area di mana prediksi model tidak sesuai dengan label yang sebenarnya.

2. 2. 16 Classification Report

Classification report adalah salah satu alat evaluasi yang digunakan untuk menilai kinerja model klasifikasi. Dalam konteks klasifikasi penyakit medis, penting untuk mengevaluasi kinerja model dengan metrik yang bisa menggambarkan seberapa baik model dalam membedakan antara pasien yang terinfeksi dan yang tidak terinfeksi. Berikut adalah metrik yang digunakan untuk mengevaluasi model ini:

1. Accuracy (Akurasi)

Akurasi adalah metrik yang menghitung berapa banyak prediksi yang benar (baik positif maupun negatif) dari keseluruhan prediksi yang dibuat oleh model. Dalam konteks klasifikasi penyakit, akurasi memberi tahu kita seberapa baik model dalam mengklasifikasikan pasien secara keseluruhan, baik yang terinfeksi maupun yang tidak terinfeksi(Singh et al., 2021). Namun, perlu diingat bahwa akurasi bisa menyesatkan jika dataset tidak

seimbang, misalnya jika jumlah pasien yang tidak terinfeksi jauh lebih banyak daripada yang terinfeksi. Berikut rumus untuk akurasi:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

2. Precision (Presisi)

Precision menggambarkan seberapa akurat prediksi positif yang dibuat oleh model. Dalam kasus klasifikasi penyakit medis, ini mengukur berapa banyak pasien yang benar-benar terinfeksi (positif) dari seluruh pasien yang diprediksi terinfeksi oleh model (Singh et al., 2021). Precision bisa diibaratkan seperti dokter yang memberikan diagnosa positif kepada seorang pasien: jika model memiliki Precision tinggi, maka setiap kali model mengatakan pasien tersebut terinfeksi, kemungkinan besar memang benar terinfeksi penyakit tersebut. Berikut rumus untuk *precision*:

$$Precision = \frac{TP}{TP + FP} \quad (2)$$

3. Recall (Sensitivitas)

Recall mengukur seberapa banyak pasien yang terinfeksi berhasil ditemukan oleh model dari semua pasien yang benar benar terinfeksi. Dalam dunia medis, recall bisa diibaratkan seperti kemampuan seorang dokter untuk tidak melewatkan pasien yang benar benar terinfeksi (Singh et al., 2021). Semakin tinggi recall, semakin kecil kemungkinan pasien yang benar-benar terinfeksi tetapi tidak terdiagnosis. Berikut rumus untuk *recall*:

$$Recall = \frac{TP}{TP + FN} \quad (3)$$

4. F1 Score


F1-Score adalah ukuran yang memberikan keseimbangan antara Precision dan recall. Dalam kasus medis, F1-Score sangat penting karena memberikan gambaran menyeluruh tentang kinerja model dengan mempertimbangkan baik seberapa akurat model dalam memprediksi pasien terinfeksi (Precision) maupun seberapa banyak pasien terinfeksi yang berhasil ditemukan (recall) (Singh et al., 2021). F1-Score tinggi menunjukkan bahwa model memiliki keseimbangan yang baik antara meminimalkan prediksi yang

salah (false positives) dan tidak melewatkan pasien yang terinfeksi (false negatives). Berikut rumus untuk F1-Score:

$$F1\ Score = \frac{TP}{TP + \frac{1}{2}(FP + FN)} \quad (4)$$

Setiap metrik ini memberikan pandangan yang berbeda mengenai bagaimana model bekerja. Precision lebih fokus pada keakuratan prediksi positif, recall lebih fokus pada kemampuan model dalam menemukan pasien yang terinfeksi, F1-Score memberikan gambaran keseimbangan antara keduanya, dan akurasi mengukur kinerja keseluruhan dari model. Dengan menggabungkan hasil dari Precision, Recall, F1-Score, dan Akurasi, kita mendapatkan gambaran yang lebih jelas tentang seberapa efektif model dalam mengklasifikasikan pasien yang terinfeksi dan yang tidak terinfeksi dalam konteks penyakit medis

2. 2. 17 ROC dan AUC



Gambar 2. 8 ROC dan AUC (Sarang Narkhede, 2018)

ROC (Receiver Operating Characteristic) curve dan AUC (Area Under the Curve) merupakan dua metrik yang sangat penting dalam mengevaluasi kinerja model klasifikasi biner, terutama dalam konteks medis. ROC curve dapat diibaratkan sebagai alat diagnostik yang menunjukkan seberapa baik model dapat membedakan antara dua kondisi, misalnya antara pasien yang terinfeksi suatu penyakit dan yang tidak terinfeksi (Hajian-Tilaki, 2013). Pada grafik ROC, sumbu Y mewakili True Positive Rate (TPR), yang

menggambarkan kemampuan model dalam mengidentifikasi pasien yang benar-benar terinfeksi (recall)(Singh et al., 2021), sedangkan sumbu X mewakili False Positive Rate (FPR), yang menunjukkan berapa banyak pasien yang sehat yang salah diklasifikasikan sebagai terinfeksi. Menghitung TPR dan FPR dapat menggunakan rumus:

$$TPR = \frac{TP}{TP + FN} \quad (5)$$

$$FPR = \frac{FP}{FP + TN} \quad (6)$$

Semakin dekat kurva ROC ke sudut kiri atas (0,1), semakin baik model dalam membedakan kedua kondisi tersebut. AUC di sisi lain, dapat diibaratkan sebagai skor keberhasilan dari suatu tes medis. AUC mengukur area di bawah ROC curve dan memberikan nilai antara 0 hingga 1, yang menggambarkan kemampuan model dalam membedakan antara dua kondisi. Nilai AUC yang tinggi, misalnya mendekati 1, menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam membedakan pasien yang terinfeksi dari yang tidak terinfeksi, sedangkan nilai AUC yang mendekati 0.5 menunjukkan bahwa model tidak lebih baik dari tebakan acak.(Jasman et al., 2022)

2. 2. 18 Dice Coefficient

Dice Coefficient adalah salah satu metrik evaluasi yang paling umum digunakan dalam segmentasi gambar, dikenal juga dengan nama lain seperti *F1 Score*, *DScore*, *DSC*, atau *overlap index*. Ini dikembangkan secara independen oleh Thorvald Sørensen dan Lee-Raymond Dice(Ataş, 2023). Dice Coefficient digunakan untuk mengukur kesamaan atau tingkat tumpang tindih antara dua sampel atau dua set data, yaitu antara hasil segmentasi yang diprediksi (*predicted segmentation result*) dan area segmentasi yang sebenarnya atau *ground truth* (mask)(Shim et al., 2022). Dalam penggambarannya, Dice Coefficient dapat dihitung dengan rumus:

$$Dice = \frac{2 | X \cap Y |}{| X | + | Y |} \quad (7)$$

Dimana $X \cap Y$ adalah sebuah ukuran (jumlah piksel) dari irisan (*intersection*) antara set X dan set B. Sedangkan $|X| + |Y|$ merupakan jumlah total ukuran kedua set. Atau dalam konteks *Confusion Matrix* dapat dinyatakan sebagai:

$$Dice = \frac{2TP}{2TP + FP + FN} \quad (8)$$

Dimana TP adalah *true positive*, FP adalah *false positive*, dan FN adalah *false negative* (Yousef et al., 2023). Dalam konteks ini:

- TP (*True Positive*) adalah jumlah piksel yang diprediksi sebagai objek dan memang benar objek (tumpang tindih antara prediksi dan ground truth objek).
- FP (*False Positive*) adalah jumlah piksel yang diprediksi sebagai objek tetapi sebenarnya bukan objek (area prediksi yang tidak tumpang tindih dengan ground truth objek).
- FN (*False Negative*) adalah jumlah piksel yang seharusnya objek (ground truth) tetapi tidak diprediksi sebagai objek (area ground truth objek yang tidak diprediksi).

Nilai Dice Coefficient berada dalam rentang 0 hingga 1, dengan nilai 0 menunjukkan tidak ada tumpang tindih dan nilai 1 menunjukkan tumpang tindih sempurna antara prediksi dan ground truth. Metrik ini sering dibandingkan dengan Jaccard Index (Intersection over Union)(Ataş, 2023), karena keduanya mengukur aspek yang sama yaitu kesamaan spasial(Yousef et al., 2023). Namun, Dice Coefficient cenderung memberikan nilai yang sedikit lebih tinggi dan konsisten dalam banyak kasus, serta dapat dikonversi ke Jaccard dengan rumus tertentu. Selain sebagai metrik utama dalam evaluasi segmentasi citra, Dice Coefficient digunakan untuk menilai akurasi tumpang tindih antara prediksi dan ground truth, metrik ini juga diadopsi sebagai dasar fungsi Dice Loss yang dioptimalkan selama pelatihan(Ataş, 2023; Jha et al., 2019). Dice Coefficient terbukti efektif pada berbagai studi segmentasi, baik untuk citra medis maupun citra satelit, dan unggul dalam menangani ketidakseimbangan antara objek dan latar belakang.

2. 3 Kerangka Pemikiran

Tabel 2. 2 Kerangka Pemikiran


Masalah		
Tuberkulosis (TBC) merupakan penyakit menular yang hingga kini masih menjadi masalah kesehatan global, terutama di negara berkembang. Deteksi dini TBC sangat krusial untuk mengurangi angka morbiditas dan mortalitas. Namun, keterbatasan sumber daya seperti kurangnya tenaga ahli radiologi, variasi kualitas gambar X-ray, serta kemiripan pola radiologis TBC dengan penyakit paru lain seperti pneumonia dan kanker paru, menyebabkan diagnosis TBC menjadi sulit, lambat, dan rentan terhadap kesalahan. Sistem deteksi berbasis AI yang ada pun sering mengalami kendala seperti overfitting, ketidakseimbangan kelas, rendahnya akurasi akibat keterbatasan dataset, dan kurangnya kepercayaan pada hasil.		
Tujuan		
Mengembangkan model deteksi TBC berbasis citra X-ray dada yang akurat, efisien, dan tahan terhadap masalah teknis seperti overfitting, ketidakseimbangan kelas, serta variasi kualitas citra dengan menggunakan gabungan dataset Montgomery dan Shenzhen untuk menghasilkan sistem yang mampu membedakan paru normal dengan TBC. Meningkatkan kepercayaan dengan transparansi model menggunakan XAI guna meminimalisir risiko salah diagnosis dan membantu menjelaskan hasil model.		
Eksperiment/Analisa		
Tools	Data	Metode
a) Kaggle sebagai platform penyedia dataset, serta alat untuk melakukan eksplorasi, <i>preprocessing</i> data dan menjalankan model.	a) Dataset Segmentasi: Berisi 704 gambar X-ray dada dengan label berupa gambar mask. b) Dataset Klasifikasi: Berisi 4200 gambar X-ray dada dengan label TBC atau Normal	a) Klasifikasi menggunakan model CNN untuk mengekstraksi berbasis arsitektur DenseNet121.
b) Python sebagai bahasa pemrograman dan mengolah data serta	c) Penggabungan dan kombinasi data untuk meningkatkan variasi	b) Segmentasi menggunakan CNN dengan arsitektur U-Net c) Evaluasi model menggunakan Dice

mengembangkan model.	anatomi dan kualitas citra.	Coefficient, AUC-ROC, Confusion Matrix, serta Classification Report untuk menghitung akurasi, precision, recall, F1-Score.
c) TensorFlow sebagai libraries untuk deep learning dan fine tuning model.	d) Data citra mask dari kedua dataset untuk mendukung segmentasi	
Pengujian dan Validasi Hasil		
Pengujian model dilakukan dengan dataset yang dibagi menjadi data training (latih) sebesar 70%, data validasi 15%, dan data testing (uji) sebesar 15%. Validasi model menggunakan Confusion Matrix dimana nilai akurasi, precision, recall, F1-Score dihitung untuk menilai performa model. Visualisasi menggunakan Grad-CAM untuk memastikan bahwa model fokus pada area anatomi yang relevan.		
Hasil		
Pengembangan model CNN dengan arsitektur DenseNet121 dan U-Net untuk mendeteksi Tuberkulosis berbasis citra X-ray dengan: a) Model klasifikasi TBC memiliki tingkat akurasi $\geq 90\%$. b) Penggabungan beberapa dataset untuk meningkatkan hasil dan keandalan model. c) Transparansi model menggunakan XAI dalam mendukung keputusan CNN. d) Tingkat AUC-ROC mendekati 1 sebagai indikator kekuatan klasifikasi.		

BAB III

METODE PENELITIAN

Pada dasarnya TBC masih menjadi masalah dalam morbiditas dan mortalitas global yang serius, selain itu interpretasi manual citra X-ray dada sulit dilakukan karena memakan waktu, memerlukan keahlian tinggi, dan rentan kesalahan, serta keterbatasan tenaga medis spesialis. Telah dilakukan beberapa penelitian terkait deteksi dini Tuberkulosis berbasis citra X-Ray. Metode penelitian deteksi Tuberkulosis pada citra X-Ray dada menggunakan CNN dengan arsitektur DenseNet121 dan U-Net mencakup beberapa tahapan, berikut merupakan ilustrasi dari alur kerja penelitian.



Gambar 3. 1 Flowchart Penelitian

Secara umum, gambar 3.1 diatas memberikan Gambaran alur penelitian yang dimulai dari pengambilan citra X-Ray dari dataset khusus X-Ray, proses pre-processing, pembagian data, pelatihan model dengan CNN, evaluasi model, pengimplementasian XAI, dan dokumentasi hasil penelitian. Berikut ini adalah informasi terkait tahapan yang dilakukan penulis dalam pelaksanaan penelitian ini:

3. 1 Instrumen Penelitian



Penelitian ini dijalankan dengan tujuan bertujuan membantu masyarakat umum, terutama untuk para tenaga medis, agar lebih mudah mendeteksi Tuberkulosis menggunakan gambar X-ray. Dengan memanfaatkan teknologi pengolahan citra digital yaitu Deep Learning Convolutional Neural Network (CNN)


dengan arsitektur DenseNet121 untuk mendeteksi penyakit TBC melalui sistem klasifikasi yang dirancang. Instrumen yang digunakan dalam penelitian ini meliputi informasi terkait data, dan perangkat yang digunakan.

3. 1. 1 Informasi Data

Data citra X-ray dada yang digunakan dalam penelitian ini diperoleh dari platform Kaggle dengan yaitu “Montgomery County Chest X-ray” berisi 138 gambar X-ray dada dari Montgomery County Department of Health, Montgomery County, Maryland, AS disediakan oleh U.S. National Library of Medicine (NLM) dan “Shenzhen Chest X-ray” berisi 662 gambar X-ray dada dari Rumah Sakit Rakyat Shenzhen No. 3, China disediakan oleh Chinese National Tuberculosis Control Program. Selain data citra X-ray asli, dataset ini juga menyertakan citra mask biner yang sesuai untuk mendukung proses segmentasi. Untuk setiap citra mask memiliki nama yang sesuai dengan citra X-Ray aslinya namun dipisahkan oleh folder yang berbeda, misalnya “image/1000.png” untuk citra asli dan “mask/1000.png” untuk citra mask. Data ini dipublikasikan pada tahun 2014 dapat diakses dengan <https://www.kaggle.com/datasets/iamtapendu/chest-x-ray-lungs-segmentation> yang berisikan koleksi citra xray dada dengan label PTB (Positive-Tuberculosis) dengan nilai 1 (PTB) dan 0 (Normal)

Tabel 3. 1 Informasi Data

Normal	Tuberkulosis
	



3. 1. 2 Peralatan Penelitian

Dalam penelitian ini, berbagai peralatan dan perangkat yang digunakan untuk mendukung proses "Klasifikasi Tuberkulosis Berbasis Citra X-Ray Dada Dengan Explainable AI Menggunakan Densenet121 dan Grad-CAM" Perangkat yang digunakan yaitu laptop Lenovo IdeaPad Gaming 3 15ARH7 dengan spesifikasi sebagai berikut:

Tabel 3. 2 Peralatan Penelitian

Jenis Perangkat	Spesifikasi	
Perangkat Keras	<i>Processor</i>	AMD Ryzen 5 6600H with Radeon Graphics (12 CPUs), ~3.30 GHz
	RAM	16,0 GB
	<i>Graphic card</i>	NVIDIA GeForce RTX 3050
Perangkat Lunak	Sistem Operasi	64-bit Windows 11
	Alat Penelitian	Kaggle

3. 2 Prosedur Pengumpulan Data

3. 2. 1 Observasi


Prosedur pengumpulan data pada penelitian ini dilakukan dengan beberapa langkah, seperti berikut. Pertama yaitu mengidentifikasi kebutuhan data dengan menentukan jenis data yang diperlukan. Pada penelitian ini membutuhkan jenis data citra xray dada yang berasal dari pasien dengan keadaan paru-paru normal dan pasien positif TBC. Penelitian ini juga membutuhkan data mask dari citra xray dada dimana menyoroti bagian paru dengan warna putih dan sisanya hitam untuk kebutuhan segmentasi citra. Kemudian pengumpulan dataset citra xray dada beserta mask diambil dari Kaggle dengan total 704 citra xray dari dua dataset yang berbeda yaitu Montgomery Chest X-rays dan Shenzhen Chest X-rays. Setelah itu mengatur dataset dalam struktur folder yang rapi dengan nama file yang sama untuk data X-Ray asli dengan mask di folder yang berbeda. Langkah terakhir, melakukan preprocessing pada data citra sesuai dengan input pada model sebelum dilakukannya pelatihan model.

3. 2. 2 Studi Pustaka

Penelitian ini memanfaatkan arsitektur DenseNet121 untuk melakukan klasifikasi dada dan arsitektur U-Net untuk melakukan segmentasi pada data citra X-ray. Studi pustaka yang telah dikaji memberikan dasar teoritis yang kuat untuk memahami konsep utama dalam pendeteksian TBC berbasis citra X-Ray dengan menggunakan model CNN arsitektur DenseNet121 dan U-Net serta pemanfaatan dataset public yang tersedia pada platform Kaggle. Teknik evaluasi yang dibahas dalam studi pustaka memastikan bahwa arsitektur yang diterapkan mampu mencapai kinerja yang optimal. Oleh karena itu, studi pustaka ini berperan sebagai landasan penting dalam mencapai tujuan penelitian yang telah diterapkan.

3.3 Pre-processing Data

Pre-processing adalah salah satu langkah yang sangat penting dalam mempersiapkan dataser agar siap digunakan dalam proses pelatihan model deep learning. Langkah ini dilakukan untuk memastikan bahwa gambar-gambar dalam dataset berada dalam kondisi terbaik dan konsisten, sehingga dapat mengefektifkan dan mengefisienkan model dalam belajar/training. Pada pre-processing dilakukan beberapa tahapan, antara lain:



Gambar 3. 2 Alur Pre-Processing Data

1. Import Data

Pada tahap ini, semua data baik gambar maupun teks yang menunjukkan label dan fitur lain yang berada dalam dataset diakses, Terdapat 2 jenis gambar yang digunakan, yaitu gambar X-Ray asli dan gambar mask. Pada tahap ini juga dilakukan import semua library yang dibutuhkan dalam melakukan pemodelan.

2. Ekplorasi Data

Tahap ini membaca dan mempelajari dataset kemudian dilakukan analisis data untuk mengetahui karakteristik atau pola dataset yang digunakan, seperti menampilkan gambar, melihat dimensi (height, width, channel), memeriksa distribusi label.

3. Pemberihan Data

Pembersihan data melibatkan penghapusan gambar yang rusak atau tidak sesuai untuk memastikan semua data memiliki format yang konsisten

seperti (ukuran, channel, dtype). Ini juga menghilangkan data yang duplikat untuk meminimalisir overfitting, bias, inefisiensi.

4. Resolusi and Resize

Setiap gambar yang ada pada dataset ini baik citra asli maupun citra mask dilakukan perubahan ukuran / resize untuk menentukan dimensi gambar dalam satuan piksel seperti 128x128, 224x224, 256x256, 1024,1024 dan seterusnya tergantung kebutuhan model. Dengan melakukan ini dapat menyeragamkan ukuran input gambar pada model dan mengefisienkan kerja model

5. Normalisasi Gambar

Langkah selanjutnya adalah normalisasi gambar. Normalisasi gambar dilakukan dengan menyelaraskan skala nilai ke rentang 0 sampai 1 dengan cara membaginya dengan 255. Langkah ini dapat membantu mengurangi variabilitas data dan mempercepat proses pelatihan karena perbedaan skala antara piksel gambar yang kecil sehingga model dapat lebih fokus pada fitur-fitur yang relevan.

6. Pembagian Data Segmentasi

Penelitian ini membagi dataset segmentasi menjadi 3 bagian data yaitu: data training untuk melatih model, data validasi untuk memvalidasi data training pada tiap *epoch* sehingga dapat mengukur performa model, dan data testing untuk mengevaluasi kinerja akhir model.

7. Augmentasi

Augmentasi dilakukan untuk memperbanyak variasi data pelatihan dengan transformasi seperti rotasi, flipping, atau zoom. Teknik ini berguna untuk meningkatkan kemampuan generalisasi model dan menghindari *overfitting*.

8. Segmentasi Data U-Net

Langkah ini bertujuan untuk memisahkan area penting dari gambar, pada penelitian ini memisahkan paru dengan organ lainnya. Langkah segmentasi dilakukan dengan memanfaatkan arsitektur U-Net yang dirancang khusus untuk segmentasi citra yang memiliki *encoder* dan

decoder untuk menghasilkan mask segmentasi biner dengan nilai 0 dan 1. Ini dapat membantu model memfokuskan pada area area yang relevan dan mendukung proses analisis.

9. Evaluasi Segmentasi

Model segmentasi dievaluasi menggunakan metrik seperti *Dice Coefficient* untuk mengukur akurasi tumpang tindih antara *mask* prediksi dan *ground truth*, sehingga dapat menilai kualitas segmentasi yang dihasilkan.

10. Inferensi

Inferensi dilakukan dengan menerapkan model segmentasi U-Net terhadap gambar baru atau dataset klasifikasi untuk menghasilkan prediksi mask, sehingga membantu memfokuskan area analisis pada bagian paru-paru.

11. Masking

Masking adalah proses mengaplikasikan *mask* hasil segmentasi ke citra X-ray untuk menyaring area non-paru, sehingga input model klasifikasi hanya berisi informasi yang relevan dengan deteksi Tuberkulosis.

3. 4 Pembagian Data


Pada dataset yang digunakan di penelitian ini dilakukan pembagian menjadi 3 bagian data yaitu: Data Training sebesar 70% yang digunakan untuk melatih model, Data Validasi sebesar 15 % yang digunakan untuk memvalidasi data training pada tiap epoch sehingga dapat mengukur performa model, dan Data Testing sebesar 15% yang digunakan untuk mengevaluasi kinerja akhir model. Pembagian data menggunakan library *scikit-learn* dengan *random state 42* untuk membagi data secara acak sehingga memastikan distribusi yang merata antara kedua kelas, menghindari bias dalam pelatihan dan evaluasi. Teknik *K-Fold Cross Validation* juga diterapkan pada data training dan validasi guna menghindari ketergantungan terhadap satu subset data. Pembagian ini memastikan bahwa data yang digunakan untuk pengujian model tidak tumpang tindih dengan data pelatihan sehingga mengurangi resiko *overfitting* dan memberikan estimasi performa yang lebih stabil.

3.5 Arsitektur Model CNN

Model yang diusulkan pada penelitian ini adalah Convolutional Neural Networks (CNN) menggunakan arsitektur DenseNet121 untuk klasifikasi dan Arsitektur U-Net untuk segmentasi dari gambar X-ray dada untuk mendeteksi Tuberkulosis. Kedua arsitektur ini dipilih karena kemampuannya dalam menangkap fitur spasial dan tekstural yang kompleks. DenseNet121 unggul dalam mengekstraksi fitur mendalam berkat koneksi antar layernya yang padat, sedangkan U-Net efektif dalam memetakan structural anatomi melalui proses encoder dan decoder.

3.5.1 DenseNet-121

Pada penelitian ini, proses klasifikasi dilakukan dengan arsitektur DenseNet121 dengan memanfaatkan *dense connectivity* agar setiap lapisan menerima input dari seluruh lapisan sebelumnya melalui struktur yang disebut *dense block*. Masing-masing *dense block* terhubung dengan *dense block* berikutnya sehingga memungkinkan *dense block* terakhir bisa menggunakan keluaran dari *dense block* pertama dan aliran informasi dapat lebih efisien. DenseNet121 memiliki 8 juta parameter yang terdiri dari kernel, bias, dan parameter normalisasi di seluruh *dense block*.



Gambar 3. 3 Arsitektur DenseNet121

Citra X-ray yang telah diatur ukurannya $224 \times 224 \times 3$ diproses melalui layer konvolusi awal (7×7 , stride 2) dan *max pooling* (3×3), dilanjutkan dengan

empat *dense block* yang masing-masing terdiri dari 6, 12, 24, dan 16 *dense layer*. Setiap *dense layer* menerapkan *batch normalization*, ReLU, dan 3×3 *convolution*, serta menerima concatenated output dari seluruh layer sebelumnya dalam *block* yang sama. Antardense *block* dipisahkan oleh *transition layer* yang melakukan 1×1 *convolution* dan *average pooling* untuk reduksi dimensi.

Densenet121 diatur dengan `include_top=false` untuk menghapus bagian *fully connected layers* sehingga hanya bagian konvolusi yang digunakan dan ditambahkn 1 unit layer aktivasi *sigmoid* yang akan memberikan prediksi probabilistik dalam klasifikasi biner. Aktivasi *sigmoid* menghasilkan output antara 0 dan 1 (Normal dan TBC). Pengaturan parameter pelatihan lainnya seperti *learning rate* sebesar 0.001 guna meminimalisir *overjump*, ukuran batch sebesar 8 agar stabil dan tidak terlalu boros memori, jumlah epoch sebanyak 25 agar tidak memakan waktu terlalu lama. Optimizer Adam juga digunakan karena konvergen lebih cepat dan stabil, serta penggunaan *Binary Crossentropy* untuk menghitung error model (*Loss Function*).

3.5.2 U-Net


Arsitektur U-Net pada penelitian ini dirancang secara khusus untuk segmentasi citra medis X-ray yang memiliki struktur *encoder* dan *decoder* simetris. *Encoder* mengekstraksi fitur penting melalui konvolusi dan *downsampling* menggunakan *maxpooling*, sedangkan *decoder* merekonstruksi resolusi spasial dengan *upsampling* dan *transposed convolution* untuk menghasilkan peta segmentasi (*ground truth mask*). Dengan memanfaatkan *skip connections* yang menghubungkan fitur dari *encoder* langsung ke *decoder* dengan ukuran yang sama sehingga segmentasi lebih presisi karena informasi spasial dari fitur awal tetap terjaga.

U-Net terdiri dari 4 blok *encoder* dan 4 blok *decoder* Dimana masing maisngnya mempunyai dua layer konvolusi (3×3 kernel), *batch normalization*, dan *ReLU activation*, serta kemudian diikuti *maxpooling* untuk mengurangi resolusi. Pada *decoder*-nya dilakukan *upsampling* melalui *transposed*

convolution dan penggabungan (*concatenate*) fitur dari *decoder*, serta kemudian diikuti oleh dua later konvolusi. Output dari model ini berupa *binary mask* yang menunjukkan area *Region of Interest* (ROI) dari paru paru yang tersegmentasi dari gambar X-ray dada. Kemudian dilakukan proses *ROI extraction* dimana *binary mask* akan digabungkan dengan gambar asli X-ray paru paru.

3. 6 Explainable Artificial Intelligence (XAI)

Setelah model CNN (DenseNet121) selesai dilatih dan dievaluasi, pendekatan XAI diterapkan untuk memberikan interpretasi visual terhadap hasil klasifikasi Tuberkulosis pada citra X-ray dada menggunakan Teknik Grad-CAM (*Gradient-weighted Class Activation Mapping*). Grad-CAM bekerja dengan menghitung gradien dari kelas target terhadap peta fitur pada layer konvolusi terakhir dan menghasilkan heatmap yang menunjukan bagian gambar mana yang paling mempengaruhi hasil prediksi model. Karena model DenseNet121 dikonfigurasi dengan `include_top=false`, maka visualisasi Grad-CAM berfokus pada output dari layer konvolusi terakhir yang menyimpan informasi spasial dari gambar asli.



Gambar 3. 4 Visualisasi Grad-CAM (Sharma et al., 2024)

Meskipun XAI meningkatkan transparansi pada model, namun penerapan XAI menghadapi tantangan bias algoritmik akibat data pelatihan yang mengandung bias sehingga menghasilkan keputusan yang tidak adil atau tidak akurat (Gading Rayya Samita et al., 2024). Selain itu model XAI bisa jadi menyorot area yang tidak relevan karena kebisingan gradient atau ketergantungan pada segmentasi superpiksel yang menyebabkan overfitting terhadap noise (Di Martino and Delmastro, 2023). Teknik XAI post-hoc memiliki keterbatasan seperti kurang konsisten terhadap penjelasan yang diberikan, karena ketergantungan pada input yang berbeda. Radiolog atau pakar medis memvalidasi bahwa metode visualisasi

seperti Grad-CAM sangat membantu dalam memahami bagaimana model membaca citra medis(Alfina et al., 2024; Di Martino and Delmastro, 2023). Dengan begitu, pendekatan ini dapat meningkatkan kepercayaan klinis terhadap hasil klasifikasi TBC berbasis citra X-ray dada.

3. 7 Evaluasi

Evaluasi merupakan tahapan penting setelah pelatihan model dilakukan untuk menilai kinerja model dalam mendeteksi penyakit Tuberkulosis pada gambar X-ray dada. Beberapa metrik evaluasi digunakan dalam penelitian ini untuk mengukur kinerja model, seperti Confusion Matrix, Classification Report, ROC dan AUC, Dice Coefficient. Metrik-metrik ini memberikan gambaran menyeluruh terkait seberapa baik sebuah model dalam membedakan antara satu kelas dengan kelas yang lain. Selain itu penggunaan XAI bukan hanya sebagai tambahan visualisasi model, tetapi juga menjadi bagian komponen esensial dalam mendukung keputusan medis. Dengan menyediakan penjelasan yang transparan dan dapat ditelusuri atas hasil prediksi model adalah Convolutional Neural Networks (CNN) sehingga tenaga medis dapat memverifikasi, memahami, dan menilai dasar keputusan model dengan lebih objektif. Dalam konteks diagnosis atau deteksi penyakit, hal ini sangat penting karena akuntabilitas dan interpretabilitas menjadi faktor penentu yang dapat meningkatkan kepercayaan klinis.

BAB IV

HASIL PENELITIAN DAN PEMBAHASAN

4. 1 Eksplorasi Dataset

Penelitian ini menggunakan pendekatan segmentasi dan juga klasifikasi, sehingga membutuhkan dataset yang sesuai dengan kebutuhannya. Untuk kasus segmentasi digunakan dataset dengan judul “Chest X-ray Dataset for Tuberculosis Segmentation” yang tersedia di platform Kaggle <https://www.kaggle.com/datasets/iamtapendu/chest-x-ray-lungs-segmentation> diakses pada 14 Maret 2025. Didalamnya terdapat dua dataset yang berasal dari daerah yang berbeda, “Montgomery County Chest X-ray Dataset” dan “Shenzhen Chest X-ray Dataset”, dengan total 704 citra X-ray dada beserta gambar mask dari masing-masing gambar. Sebanyak 80% data berasal dari Shenzhen (566 gambar) dan 20% dari Montgomery (138 gambar). Semua data gambar pada dataset ini digunakan pada penelitian ini.

Dalam kasus klasifikasi digunakan dataset dengan judul “Tuberculosis (TB) Chest X-ray Database” yang diakses pada 27 Mei 2025 pada platform Kaggle dengan menggunakan URL: <https://www.kaggle.com/datasets/tawsifurrahman/tuberculosis-tb-chest-xray-dataset>. Dataset ini menggabungkan beberapa dataset citra x-ray dada yang telah disesuaikan untuk keperluan khusus klasifikasi tuberkulosis. Gabungan dataset ini berasal dari “Montgomery County Chest X-ray Dataset” sebanyak 138 gambar dan “Shenzhen Chest X-ray Dataset” sebanyak 662, keduanya termasuk kedalam National Library of Medicine Dataset (NLM), Kemudian terdapat belarus dataset yang mengandung 306 citra x-ray dada dimana semuanya terindikasi tuberkulosis dari daerah belarusia. Dilanjut dengan Radiological Society of North America (RSNA) CXR Dataset berisi sekitar 30.000 citra x-ray dada yang berasal dari National Institutes of Health (NIH) Clinical Center, Amerika Serikat, namun dalam gabungan dataset ini hanya diambil 3094 citra x-ray normal. Gabungan dataset ini menghasilkan 4200 gambar dengan 3500 gambar normal dan 700 gambar

tuberkulosis. Ringkasan penggunaan data dalam penelitian ini dapat dilihat dalam table berikut:

Tabel 4. 1 Distribusi Data

Penggunaan	Asal	Jumlah	Label		Judul dataset
			Normal	Tuberkulosis	
Segmentasi	Mongemetry	138	80	58	NLM Dataset
	Shenzhen	566	279	287	NLM Dataset
	Total	704	359	345	
Klasifikasi	Mongemetry	138	80	58	NLM Dataset
	Shenzhen	662	326	336	NLM Dataset
	Belarus	306	0	306	Belarus Dataset
	NIH Clinical Center, USA	3094	3094	0	RSNA CXR Dataset
	Total	4200	3500	700	

4. 1. 1 Dataset Segmentasi


Dataset segmentasi yang digunakan memiliki rata-rata ukuran gambar asli (3000, 3000, 3) dan bertipe data uint8, dengan nilai piksel maksimum 255 dan minimum 0. Dataset ini terbagi menjadi dua kelas, yaitu *Positif Tuberkulosis* (PTB=1) dan Normal (PTB=0). Dataset ini sangat cocok untuk kasus segmentasi karena berisi citra x-ray dan masker paru-paru ground truth yang sesuai dan dianotasi oleh ahli radiolog dengan jumlah yang sama yaitu 704 gambar (Rahman et al., 2020). Didalamnya terdapat metadata klinis yang mencakup informasi seperti id gambar, jenis kelamin, usia, asal daerah, label

PTB, serta catatan kondisi klinis tambahan seperti "secondary PTB" atau "normal". Berikut contoh isi dari table file MetaData.csv

Tabel 4. 2 Sample Data MetaData.csv Dataset Segmentasi


id	gender	age	county	ptb	remarks
1000	male	31	Shenxhen	0	normal
1001	male	64	Shenxhen	0	normal
1002	male	35	Shenxhen	0	normal
1003	male	32	Shenxhen	1	STB, ATB, tuberculosis pleuritis
1004	male	2	Shenxhen	1	secondary PTB in the bilateral upper field

Dapat dilihat pada tabel 4. 2 diatas bahwa pada kolom ‘id’ mewakili nama file gambar dari data tersebut. Pada dataset ini, gambar X-ray dan mask memiliki nama file yang sama, namun disimpan di folder yang berbeda, folder “image” untuk gambar x-ray dada asli dan folder “mask” untuk gambar mask. Adapun contoh gambar yang tersedia pada dataset segmentasi ini dapat dilihat pada gambar-gambar berikut:



Gambar 4. 1 Sampel X-ray Dada Berlabel Dataset Segmentasi

Selain gambar asli X-ray dada terdapat juga mask dari masing-masingnya. Berikut contoh gambar mask paru yang ada dalam dataset segmentasi:



Gambar 4. 2 Sampel Mask

4. 1. 2 Dataset Klasifikasi


Dataset klasifikasi ini menyimpan citra x-ray dada terpisah antara normal dan tuberculosis. Folder “Normal” berisi 3500 citra x-ray dada dengan kondisi paru-paru normal, sedangkan folder “Tuberculosis” berisi 700 citra x-ray dada dengan kondisi paru paru tuberculosis. Terdapat file Normal.metadata.xlsx dan Tuberculosis.metadata.xlsx yang berisi nama file, format gambar, ukuran gambar, dan URL sumber dari gambar tersebut. Berikut adalah contoh isi dari metadata.xlsx

Tabel 4. 3 Sample Data Metadata.xlsx Dataset Klasifikasi

FILE NAME	FORMAT	SIZE	URL
Normal-1	PNG	512*512	https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4256233/
Normal-2	PNG	512*512	https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4256233/
Normal-3	PNG	512*512	https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4256233/
Tuberculosis-1	PNG	512*512	http://tuberculosis.by/
Tuberculosis-2	PNG	512*512	http://tuberculosis.by/

Data diatas menampilkan gabungan dari Normal.metadata.xlsx dan Tuberculosis.metadata.xlsx. Dataset ini memiliki ukuran gambar asli (512, 512, 3) dengan nilai piksel maksimum 255 dan minimum 0. Dari tabel 4. 1 dapat disimpulkan bahwa dataset klasifikasi mengalami ketidakseimbangan label (label imbalance), sehingga diperlukan teknik penanganan seperti oversampling atau undersampling. Namun pada keterangan dataset ini

menyebutkan tambahan dataset yang dapat diunduh terpisah yaitu National Institute of Allergy and Infectious Diseases (NIAID) TB Dataset yang terdiri dari 3000 citra x-ray dada positif tuberkulosis namun hanya digunakan 2800 saja untuk menyeimbangan gambar x-ray paru tuberculosis menjadi 3500. Ini berasal dari 8 negara yang berbeda yaitu Azerbaijan, Belarus, China, Georgia, India, Kazakhstan, Kyrgyzstan, dan Moldova. Adapun contoh gambar dari dataset klasifikasi ini dapat dilihat pada gambar-gambar berikut:



Gambar 4. 3 Sampel X-ray Dada Dataset Klasifikasi

4. 2 Pre-processing Data


Pada tahap pre-processing, gambar-gambar dan data yang ada pada dataset yang digunakan diproses agar siap digunakan dalam pelatihan model deep learning sehingga dapat mengefektifkan dan mengefisienkan model dalam belajar/training. Pada Bab 3. 3 menyebutkan import data, eksplorasi data, pembersihan, resolusi dan resize, normalisasi, dan segmentasi. Setelah langkah import dan eksplorasi dilakukan, selanjutnya pembersihan, resolusi, resize, normalisasi, hingga masking dataset klasifikasi menggunakan hasil segmentasi U-Net, kemudian dilanjutkan pembagian dataset klasifikasi.

4. 2. 1 Pembersihan

Langkah awal dimulai dengan pengecekan missing value pada MetaData.csv dan file gambar yang hilang, untuk memastikan seluruh data

memiliki pasangan file yang tersedia. Proses ini mencakup penggunaan `.isnull()` untuk mendeteksi nilai kosong dan `.exists()` untuk memverifikasi keberadaan file gambar. Selanjutnya dilakukan identifikasi dan penghapusan data duplikat menggunakan `.duplicated()` agar tidak terjadi bias atau overfitting dalam pelatihan model. Kemudian, validasi label dilakukan dengan penggunaan fungsi `.unique()` dan `.isin([0, 1])` untuk memastikan data dengan label 0 (Normal) dan 1 (Positive TB) yang digunakan.

Pada dataset segmentasi distribusi kelas tergolong balance, sehingga tidak memerlukan teknik penyeimbangan kelas. Namun pada dataset klasifikasi terindikasi label imbalance, sehingga dilakukan undersampling dengan target 700 data, di mana akan merubah jumlah data dari 4200 gambar (700 PTB, 3500 Normal) menjadi 1400 gambar (700 PTB, 700 Normal). Undersampling Random dilakukan dengan menghapus sampel dari kelas mayoritas secara acak hingga menyisakan 700 gambar untuk proses selanjutnya.



Gambar 4. 4 UnderSampling Dataset Klasifikasi


4. 2. 2 Resolusi, Resize, dan Normalisasi

Pada awalnya gambar asli pada dataset segmentasi memiliki rata-rata resolusi yang sangat tinggi (3000, 3000, 3) piksel sehingga memerlukan proses

resizing, ini dilakukan pada gambar X-ray dada dan gambar mask, pada dataset klasifikasi dilakukan *resizing* dari resolusi asli (512, 512, 3) piksel menjadi seragam dengan resolusi (224, 224, 3) piksel pada semua gambarnya menggunakan *OpenCV*. *Resizing* dilakukan untuk menyesuaikan kebutuhan model sehingga efisien dalam sumber daya, waktu, dan kinerja pada saat pemrosesan. Selanjutnya dilakukan normalisasi nilai piksel pada semua data gambar yang digunakan dengan membagi setiap nilai piksel dengan 255. Normalisasi menjadikan nilai piksel selaras, yang sebelumnya memiliki nilai minimum 0 dan maksimum 255, diubah menjadi dalam skala nilai dari rentang 0 sampai 1, ini dilakukan untuk mereduksi variabilitas data dan meningkatkan kinerja model.


4. 2. 3 Pembagian Data

Pembagian dataset dilakukan dalam dua tahap menggunakan fungsi *train_test_split* dari library *scikit-learn*. Pertama, data dibagi menjadi dua dengan proporsi 70:30 dan menjadi subset pelatihan (70%) dan subset sementara (30%) menggunakan *random_state=42* dan parameter *stratify=labels*, yang memastikan distribusi label tetap seimbang di setiap subset. Selanjutnya, subset sementara tersebut dibagi dua lagi dengan proporsi 50:50 secara merata menjadi data validasi (15%) dan data pengujian (15%), juga dengan penerapan stratifikasi berdasarkan label (*stratify=y_temp*). Penerapan *stratify* bertujuan agar proporsi kelas (PTB dan Normal) tetap konsisten pada setiap subset, sehingga model dapat dilatih dan dievaluasi dengan data yang representatif dan menghindari bias label. Pembagian ini bertujuan untuk memastikan model dapat belajar secara optimal serta dievaluasi dengan data yang belum pernah dilihat sebelumnya, sehingga menghasilkan generalisasi yang lebih baik. Berikut adalah distribusi pembagian data:



Gambar 4. 5 Diagram Batang Distribusi Pembagian Dataset Segmentasi

Berdasarkan Gambar 4. 3 dapat disimpulkan bahwa distribusi kelas pada setiap subset data bersifat seimbang. *Training* set terdiri dari 492 gambar (70%) dengan 251 gambar berlabel *Normal* dan 241 *Positive TB*. Sementara itu, baik *Validation* set maupun *Testing* set masing-masing berisi 106 gambar (15%), dengan distribusi yang sama: 54 *Normal* dan 52 *Positive TB*.



Gambar 4. 6 Diagram Batang Distribusi Pembagian Dataset Klasifikasi

Berdasarkan Gambar 4. 4 dapat disimpulkan bahwa distribusi kelas pada setiap subset data bersifat seimbang. Menggunakan 1400 gambar yang dibagi menjadi tiga subset, *Training* set terdiri dari 980 gambar (70%) masing masing dengan 490 gambar untuk label *Normal* dan *Positive TB*. Sementara itu, baik *Validation* set maupun *Testing* set masing-masing berisi 210 gambar (15%), dengan distribusi yang sama masing-masing 105 untuk label *Normal* dan *Positive TB*. Perbandingan pembagian data yang digunakan pada penelitian ini dapat dilihat pada tabel berikut:

Tabel 4. 4 Perbandingan Pembagian Data Penelitian

Penggunaan	Label	Subset Data		
		Training (70%)	Validation (15%)	Testing (15%)
Segmentasi 704 gambar	Normal	251	54	54
	Tuberkulosis	241	52	52
	Total	492	106	106
Klasifikasi 1400 gambar	Normal	490	105	105
	Tuberkulosis	490	105	105
	Total	980	210	210

Berdasarkan Tabel 4.4, dapat dilihat bahwa data telah dibagi secara seimbang antara label Normal dan Tuberkulosis di setiap subset (training, validation, dan testing). Pembagian ini dilakukan untuk memastikan bahwa model tidak condong terhadap salah satu kelas dan dapat melakukan generalisasi dengan lebih baik.

4. 2. 4 Augmentasi


Teknik augmentasi data juga diterapkan pada penelitian ini untuk meningkatkan generalisasi model dan memperkaya variasi data pelatihan, seperti merotasi gambar, menggeser gambar, memperbesar/memperkecil gambar, dan lain sebagainya. Augmentasi diterapkan di kedua dataset dan hanya untuk subset training saja, subset lainnya tidak diterapkan. Ada pula parameter yang digunakan pada augmentasi dapat dilihat pada table berikut:

Tabel 4. 5 Parameter Augmentasi Data

<i>Parameter</i>	<i>Values</i>
<i>rotation_range</i>	5
<i>width_shift_range</i>	0.02
<i>height_shift_range</i>	0.02
<i>shear_range</i>	0.1

<i>zoom_range</i>	<i>0.1</i>
<i>horizontal_flip</i>	<i>False</i>
<i>vertical_flip</i>	<i>False</i>
<i>fill_mode</i>	<i>nearest</i>

Dari parameter-parameter yang diterapkan diatas, menghasilkan beberapa gambar augmentasi seperti dibawah ini:



Gambar 4. 7 Sampel Augmentasi

4. 2. 5 Segmentasi U-Net

Setelah dipastikan data dan gambar bersih dan sesuai dengan kebutuhan model, dilakukan pelatihan model segmentasi dengan dataset segmentasi menggunakan arsitektur U-Net. Segmentasi dilakukan untuk memisahkan area paru paru dengan area lain dan akan menghasilkan model untuk memprediksi *binary mask* (inferensi) yang akan diterapkan pada dataset klasifikasi. Segmentasi citra dilakukan dengan konfigurasi sebagai berikut:

Tabel 4. 6 Konfigurasi Model U-Net

<i>Function</i>	<i>Configuration</i>
<i>Architecture</i>	U-Net:

	- input size = (224, 224, 1) - Dibangun manual menggunakan Conv2D, ReLU, MaxPooling, dan Dropout
<i>Encoder Layers</i>	4 blok konvolusi dengan jumlah filter meningkat: $64 \rightarrow 128 \rightarrow 256 \rightarrow 512$ - <i>Conv2D</i> + <i>ReLU</i> + <i>MaxPooling2D</i> + <i>BatchNormalization</i> + <i>Dropout</i>
<i>Bottleneck Layer</i>	Menggunakan 1024 filter - <i>Conv2D(1024) → ReLU → Conv2D(1024) → ReLU → BatchNormalization</i>
<i>Decoder Layers</i>	4 blok konvolusi dengan jumlah filter menurun: $512 \rightarrow 256 \rightarrow 128 \rightarrow 64$ - <i>Conv2DTranspose</i> untuk upsampling - <i>Concatenate</i> dengan fitur <i>encoder</i> (<i>skip connections</i>) - <i>Conv2D</i> dan <i>ReLU</i> di setiap blok <i>decoding</i> - <i>BatchNormalization</i> - <i>Dropout</i>
<i>Output Layers</i>	Conv2D (1 filter, kernel 1×1) - Aktivasi: Sigmoid untuk menghasilkan mask biner

Setelah model U-Net dikonfigurasi, selanjutnya melatih model U-Net. Pelatihan menggunakan konfigurasi seperti berikut:


Tabel 4. 7 Konfigurasi Pelatihan Model U-Net

<i>Training Configuration</i>	
<i>Optimizer</i>	Adam: - Learning rate = 1×10^{-3}
<i>Loss Function</i>	<i>Binary Crossentropy</i>
<i>Metrics</i>	<i>Accuracy</i>
<i>Epochs</i>	25

<i>Batch size</i>	4
-------------------	---

4. 2. 6 Inferensi


Inferensi segmentasi menghasilkan prediksi mask yang akan digunakan untuk menyoroti wilayah yang relevan, sehingga model klasifikasi dapat lebih fokus dan mengurangi gangguan dari area non-paru. Proses ini membantu meningkatkan akurasi dan efisiensi klasifikasi Tuberkulosis. Gambar berikut menunjukkan hasil penerapan model U-Net terhadap citra X-ray pada dataset klasifikasi, yang menyoroti area paru-paru sebagai fokus utama klasifikasi.



Gambar 4. 8 Inferensi segmentasi U-Net

4. 2. 7 Masking

Setelah prediksi *binary mask* (inferensi) menggunakan model U-Net selesai dilakukan, selanjutnya penggabungan gambar asli dengan gambar mask (*masking*) dataset klasifikasi. Ini menghasilkan gambar baru dengan dimensi yang sama dengan gambar asli, namun area diluar paru-paru diubah menjadi hitam. Masking sendiri bertujuan untuk mengarahkan fokus pada area yang relevan (pada kasus ini paru-paru), mengurangi kompleksitas komputasi, serta meningkatkan akurasi. Berikut adalah contoh hasil masking pada citra x-ray:



Gambar 4. 1 Sample Masking X-ray Paru-paru

4.3 Konfigurasi Model DenseNet121

Penelitian ini menggunakan model klasifikasi berbasis arsitektur Densenet121 sebagai *feature extraction*. Model ini dipilih karena berdasarkan penelitian (Rahman et al., 2020; Rochmawanti et al., 2021) DenseNet mendapatkan akurasi lebih unggul dibanding model lainnya, menunjukkan kemampuannya dalam menangkap fitur spasial yang kompleks dan mendalam dari gambar X-ray. Setelah fitur diekstraksi model dilengkapi dengan lapisan tambahan untuk output klasifikasi.

Berikut merupakan konfigurasi-konfigurasi yang digunakan pada penelitian ini untuk model DenseNet121.

Tabel 4. 8 Konfigurasi Model DenseNet121

<i>Function</i>	<i>Configuration</i>
<i>Feature Extraction</i>	DenseNet-121: - bobot = “imagenet” - include_top = False - input size = (224, 224, 3)
<i>Resume Layers</i>	<i>GlobalAveragePooling2D()</i> : Mengubah fitur 2 dimensi menjadi 1 dimensi
<i>Classification Layers</i>	- <i>Dense Layer</i>: 128-unit <i>Dense layer</i> dengan fungsi aktivasi <i>ReLU</i> - <i>Dropout</i>: <i>Dropout</i> dengan tingkat 0,3 - <i>Output Layer</i>: 1-unit <i>Dense layer</i> dengan fungsi aktivasi <i>sigmoid</i>

Tabel 4. 9 Konfigurasi Pelatihan Model DenseNet121


<i>Training Configuration</i>	
<i>Optimizer</i>	Adam: - Learning rate = 1×10^{-3}
<i>Loss Function</i>	<i>Binary Crossentropy</i>
<i>Metrics</i>	<i>Accuracy</i>
<i>Epochs</i>	25
<i>Batch size</i>	32
<i>Callback</i>	<i>EarlyStopping</i> : - <i>monitor</i> ='val_loss' - <i>patience</i> =5 - <i>restore_best_weights</i> =True - <i>verbose</i> =1

4. 4 Evaluasi Model

Setelah dilakukan pelatihan model, dilakukan evaluasi untuk mengukur keandalan dan menilai kinerja model yang telah dilatih menggunakan beberapa dataset pada tabel 4. 1 dalam mengklasifikasi gambar x-ray dada khususnya pada bagian paru-paru normal dan tuberkulosis. Beberapa metrik digunakan untuk mengukur sejauh mana model dapat membedakan antara dua kelas tersebut antara lain *classification report*, *confusion matrix*, serta ROC dan AUC. Dengan menggunakan metrik-metrik ini, penulis menganalisis kemampuan model dalam mendeteksi tuberkulosis pada gambar dengan tingkat akurasi yang tinggi, baik pada kelas tuberkulosis maupun kelas normal. Kemudian adapula metrik evaluasi *dice coefficient* yang digunakan untuk mengevaluasi model segmentasi U-Net. Semua metrik-metrik dan hasil evaluasi akan dibahas secara rinci untuk memberikan gambaran yang jelas tentang efektivitas dan kinerja model yang diusulkan dalam penelitian ini.

4. 4. 1 Confusion Matrix

Confusion matrix adalah alat yang digunakan untuk menganalisis hasil klasifikasi model. Matriks ini menyajikan jumlah prediksi yang benar dan salah untuk masing-masing kelas, yaitu kelas normal dan kelas tuberkulosis. Dengan menggunakan *confusion matrix*, kita dapat menghitung metrik tambahan seperti *Precision*, *Recall*, dan *F1-Score*, yang memberikan gambaran lebih mendalam tentang bagaimana model mengklasifikasikan data. Berikut merupakan *confusion matrix* yang dihasilkan dari model yang diusulkan.



Gambar 4. 9 Hasil Evaluasi Confusion Matrix

Pada gambar diatas, merupakan tampilan dari confusion matrik yang menggambarkan kinerja model pada test set. Berdasarkan hasil yang tertera didalamnya, kelas Normal menunjukkan kinerja yang sangat baik, dengan 101 *True Positives* dan hanya 4 *False Positives*. Hal ini menunjukkan kemampuan model untuk mendeteksi kelas normal dengan tingkat akurasi yang tinggi. Sementara untuk kelas Tuberkulosis, model juga menunjukkan hasil yang memuaskan, dengan 97 *True Negatives* dan hanya 8 *False Negatives*. Meskipun terdapat sedikit kesalahan klasifikasi, dengan hasil confusion matrix

ini menegaskan bahwa model mampu membedakan kedua kelas (Normal dan Tuberkulosis) dengan cukup efektif.

4. 4. 2 Classification Report

Classification report memberikan gambaran komprehensif mengenai kinerja model dalam hal *Precision*, *Recall*, *F1-Score*, dan *Support* untuk setiap kelas. *Precision* mengukur seberapa banyak prediksi positif yang benar, sementara *Recall* mengukur kemampuan model dalam mendeteksi gambar lesi Monkeypox yang sebenarnya. *F1-Score* digunakan untuk nilai gabungan yang memberikan keseimbangan antara *Precision* dan *Recall*, yang sangat penting terutama jika distribusi data antar kelas tidak merata. *Support* menunjukkan jumlah sampel untuk setiap kelas dalam dataset uji.

Dalam kasus klasifikasi gambar x-ray dada ini, *Recall* merupakan metrik yang krusial untuk memastikan setiap kelas dikenali dengan baik oleh model. *Recall* yang tinggi menunjukkan bahwa model dapat mendeteksi hampir semua gambar dari setiap kelas dengan akurasi tinggi, dan meminimalkan kesalahan klasifikasi. Sebaliknya, *Recall* yang rendah mengindikasikan bahwa model sering salah mengklasifikasikan suatu kelas sebagai kelas lain, yang dapat mengurangi keakuratan identifikasi dalam penelitian. Di sisi lain, *Precision* menunjukkan seberapa akurat model dalam mengklasifikasikan gambar ke setiap kelas. *Precision* tinggi berarti prediksi model untuk suatu kelas jarang salah. Namun, jika *Precision* tinggi tetapi *Recall* rendah, model cenderung terlalu selektif, sehingga banyak gambar yang seharusnya termasuk dalam suatu kelas justru terlewat. Oleh karena itu, keseimbangan antara *Precision* dan *Recall*, yang tercermin dalam *F1-Score*, menjadi faktor penting dalam menilai performa keseluruhan model. Berikut merupakan *classification report* yang dihasilkan dari model klasifikasi DenseNet121 yang diterapkan pada penelitian ini.


Classification Report:				
	precision	recall	f1-score	support
Normal	0.93	0.96	0.94	105
Tuberculosis	0.96	0.92	0.94	105
accuracy			0.94	210
macro avg	0.94	0.94	0.94	210
weighted avg	0.94	0.94	0.94	210

Gambar 4. 10 Hasil Evaluasi Classification Report

Pada gambar diatas merupakan *classification report* yang dihasilkan oleh model DenseNet121, didalamnya tertera *Precision*, *Recall*, *F1-Score*, dan *Support*. Untuk kelas 0 atau Normal, dengan nilai *Support* 105 model berhasil mencapai *Precision* sebesar 0.93, *Recall* sebesar 0.96, dan *F1-Score* sebesar 0.94. Sedangkan pada kelas 1 atau Tuberkulosis dengan nilai *Support* yang sama yaitu 105 berhasil mencapai *Precision* sebesar 0.96, *Recall* sebesar 0.92, dan *F1-Score* sebesar 0.94. *Accuracy* yang dihasilkan sebesar 0.94. Secara keseluruhan, hasil model dalam membedakan kedua kelas dapat dikatakan sangat bagus dan robust, mencerminkan kinerja yang andal dalam melakukan klasifikasi tuberkulosis pada data x-ray dada.

4. 4. 3 ROC dan AUC

ROC *curve* menggambarkan *trade-off* antara *true positive rate (recall)* dan *false positive rate* pada berbagai *threshold* klasifikasi. AUC (*Area Under the Curve*) mengukur luas area di bawah ROC *curve* dan memberikan indikasi seberapa baik model dalam membedakan antara dua kelas (Normal dan Tuberkulosis). Semakin nilai AUC mendekati 1 menunjukkan semakin baik pula model dalam melakukan klasifikasi.



Gambar 4. 11 Hasil Evaluasi ROC dan AUC

Pada gambar diatas, ROC curve yang teragregasi memberikan gambaran jelas tentang kinerja model dalam membedakan kedua kelas, yaitu kelas Normal dan kelas Tuberkulosis. Model berhasil mencapai nilai AUC sebesar 0.9751 atau dapat dibulatkan menjadi 0.98 yang tertera pada gambar, ini menunjukkan bahwa kemampuan model dalam memisahkan kedua kelas sangat baik. Ini dapat dilihat dari bentuk kurva berwarna oranye yang mewakili ROC curve sangat berbeda jauh diatas garis diagonal berwarna biru, yang menandakan bahwa model memiliki tingkat klasifikasi yang jauh lebih baik dibandingkan dengan tebakan acak. Dengan AUC yang mendekati 1 model menunjukan kemampuan yang sangat baik dalam membedakan antara kelas-kelas tersebut.

4. 4. 4 Dice Coefficient


Dice coefficient digunakan sebagai metrik evaluasi untuk menilai performa model segmentasi citra medis dalam mendeteksi area patologis pada citra X-ray dada dalam kasus ini area paru-paru. Pada dasarnya dice coefficient hanya menghasilkan sebuah angka tunggal (skalar) yang menghitung tingkat

tumpang tindih antara *mask* prediksi dan *ground truth*. Nilai *Dice* berkisar antara 0 hingga 1, di mana nilai yang lebih tinggi menunjukkan tumpang tindih yang lebih besar antara hasil segmentasi model dan *mask ground truth* menjadikan segmentasi lebih akurat. *Dice coefficient* sangat efektif dalam menangani ketidakseimbangan kelas pada segmentasi spasial, terutama saat area lesi berukuran kecil dibandingkan keseluruhan citra. Berikut adalah hasil evaluasi segmentasi model U-Net pada data uji menggunakan *dice coefficient*

```
Test Loss: 0.0730, Test Accuracy: 0.9696
Dice Coefficient: 0.9393
```

Gambar 4. 12 Hasil Evaluasi Dice Coefficient

Model U-Net yang diterapkan berhasil mendapatkan nilai dice coefficient 0.9393, ini menunjukkan bahwa tumpang tindih antara *mask* prediksi dan *ground truth* mencapai hampir 94%. Nilai ini mencerminkan performa segmentasi yang sangat baik, sehingga hasilnya dapat diandalkan untuk memisahkan area paru-paru secara akurat dari latar belakang. Berikut merupakan visualisasi tumpang tindih antara *mask* prediksi dan *ground truth* dari sample acak.



Gambar 4. 13 Hasil Overlay Dice Coefficient


Gambar kiri menunjukkan *mask ground truth* berdasarkan anotasi manual sebagai acuan. Gambar tengah merupakan hasil prediksi model dalam bentuk *mask biner* yang menyoroti area paru-paru. Sementara itu, gambar kanan memperlihatkan tumpang tindih (*overlay*) antara prediksi dan *ground truth*, di mana area dengan warna hijau menunjukkan kesesuaian (*True*

Positive), warna merah menandakan prediksi berlebih (*False Positive*), dan warna biru menunjukkan area yang terlewat (*False Negative*). Nilai *dice coefficient* sebesar 0.9344 mencerminkan tingkat tumpang tindih yang sangat baik, menandakan bahwa model mampu melakukan segmentasi paru-paru dengan akurasi tinggi pada gambar tersebut.

4. 5 Explainable Artificial Intelligence (XAI)

Penelitian ini menerapkan tambahan visualisasi berbasis XAI dengan metode Grad-CAM. Grad-CAM terbukti efektif dalam menjelaskan hasil model deep learning di bidang medis, khususnya radiologi. Dalam berbagai studi, Grad-CAM digunakan untuk mengidentifikasi bagian-bagian citra CXR yang signifikan untuk keputusan klasifikasi, dengan memanfaatkan informasi spasial yang disimpan oleh lapisan konvolusional (Bhandari et al., 2022b) sehingga mengatasi masalah *black box* pada *deep learning* (Gipiškis et al., 2024; Stahlschmidt et al., 2022). Selain itu, para ahli medis menilai bahwa *heatmap* Grad-CAM sangat menguntungkan untuk analisis citra medis karena merepresentasikan wilayah paling signifikan yang terkait dengan infeksi (Sharma et al., 2024), ini menunjukkan bahwa visualisasi Grad-CAM dapat membantu menjelaskan cara kerja AI, sehingga lebih mudah dipahami dan dipercaya oleh radiolog.

Pada penelitian ini, Grad-CAM menggunakan layer konvolusional terakhir DenseNet121 yaitu '*conv5_block16_concat*' dengan parameter (5, 5) untuk *blur kernel Gaussian*, *threshold* sebesar 0,3 serta transparansi *overlay (alpha)* 0,2. Selanjutnya dipilih skema pewarnaan heatmap '*cv2.COLORMAP_JET*' yang akan menampilkan gradasi dari biru sampai merah tergantung tingkat pengaruh pikselnya pada hasil klasifikasi.



Gambar 4. 14 Visualisasi Grad-CAM

Gambar di atas menunjukkan hasil visualisasi Grad-CAM pada model klasifikasi Tuberkulosis (TB) berbasis citra X-ray dada. Kolom pertama menampilkan citra asli, kolom kedua menampilkan peta aktivasi (heatmap), dan kolom ketiga menunjukkan hasil superimposisi antara heatmap dengan citra asli. Untuk dua baris teratas yang berlabel 1 (positif TB), Grad-CAM berhasil menyoroti area paru-paru bagian tengah dan atas dengan warna kuning hingga merah terang, yang merupakan lokasi umum manifestasi TB. Ini menunjukkan bahwa model memusatkan perhatian pada area yang relevan secara klinis saat membuat prediksi. Sebaliknya, untuk dua baris terbawah yang berlabel 0 (normal), heatmap menunjukkan warna biru yang mendominasi, menandakan rendahnya aktivasi dan absennya fokus pada area mencurigakan, sesuai dengan status normal citra tersebut.

Dengan demikian, visualisasi Grad-CAM ini menunjukkan bahwa model memiliki perhatian yang tepat dan tidak menyorot area yang tidak seharusnya, meningkatkan kepercayaan terhadap interpretasi hasil klasifikasi.

4. 6 Tabel Perbandingan

Pada tahap ini, dilakukan perbandingan model yang diusulkan dengan model-model yang telah dibahas dalam jurnal penelitian lain. Perbandingan ini bertujuan untuk menganalisis dan mengevaluasi keunggulan atau kelemahan model yang dibandingkan dengan pendekatan yang sudah ada, dengan mengukur metrik evaluasi seperti akurasi, dan AUC score. Ini dilakukan berdasarkan dataset utama yaitu “Tuberculosis (TB) Chest X-ray Database” dan fokus pada kasus klasifikasi, namun teknik dan parameter yang berbeda.

Tabel 4. 10 Komparasi Penelitian Sebelumnya

Model	Segmentasi	Komposisi Data	Parameter Pembeda	Akurasi	AUC Score	Runtime
MobileNet (Nusantara and Akbar, 2024)	-	1400 gambar (80% Latih, 20% Uji)	Input size (256x256), Aktivasi Softmax	99,29%	-	300 detik
Xception (Sharma et al., 2024)	U-Net	1400 gambar (80% Latih, 10% Valid, 10% Uji)	Categorical Cross-Entropy	99.29%	0,99	-
DenseNet201 (Rahman et al., 2020)	U-Net	7000 gambar (80% Latih, 20% Uji)	Optimizer SGD, PyTorch, Normalisasi Z-Score	98,6%	0,99	1.330 detik

DenseNet121 (Too et al., 2024)	-	4200 gambar (72% Latih, 8% Valid, 20% Uji) + data lapangan untuk uji	Input size (150x150), Optimizer SGD, LearningRate 0.01, tanpa handling Label Imbalance	99,52%	-	-
DenseNet121 (Penelitian Saat Ini)	U-Net	1400 gambar (70% Latih, 15% Valid, 15% Uji)	Input size (224,224), Aktivasi Sigmoid, Binary CrossEntropy, Optimizer Adam, LearningRate 0.001, TensorFlow, Undersampling Random	94,3%	0.98	120 detik

Penelitian ini menggunakan arsitektur DenseNet121, serupa dengan pendekatan yang dilakukan oleh Too et al. (2024) dan Rahman et al. (2020) yang masing-masing menggunakan DenseNet121 dan DenseNet201. Ketiganya menunjukkan efektivitas DenseNet dalam klasifikasi citra X-ray dada. Namun, terdapat perbedaan signifikan dalam konfigurasi dan strategi pelatihan. Penelitian saat ini menggabungkan DenseNet121 dengan segmentasi U-Net, menggunakan *optimizer Adam*, aktivasi *Sigmoid*, *binary cross-entropy*, serta menerapkan *undersampling* untuk menangani ketidakseimbangan label, sedangkan (Too et al., 2024) tidak menggunakan segmentasi maupun balancing data, dan (Rahman et al., 2020) menggunakan optimizer SGD dengan framework *PyTorch* serta normalisasi

Z-Score. Dari sisi performa, akurasi model saat ini mencapai 94,3% dengan AUC 0,98 dalam runtime hanya 120 detik, sedangkan model DenseNet201 membutuhkan waktu hingga 1330 detik dengan akurasi 98,6% dan AUC 0,99. Dengan demikian, meskipun akurasi sedikit lebih rendah, pendekatan penelitian ini lebih efisien secara komputasi dan penerapan dapat lebih fleksibel pada perangkat yang lebih ringan.

4. 7 Studi Ablasi

Studi ablasi dilakukan untuk mengevaluasi kontribusi teknik tertentu dalam pelatihan model dan dampaknya terhadap performa. Salah satu eksperimen membandingkan model dengan dan tanpa data augmentasi untuk melihat pengaruhnya terhadap generalisasi dan risiko *overfitting*, serta kemampuannya menghadapi variasi citra X-ray paru-paru. Selain itu, diuji juga perubahan nilai K dalam K-Fold *cross-validation* untuk menilai stabilitas model pada skenario validasi yang berbeda. Hasil studi ini membantu menentukan konfigurasi terbaik untuk meningkatkan performa, akurasi dan keandalan model klasifikasi.

Tabel 4. 11 Studi Ablasi

Model	Avg Validation	Best Validation	Avg Time/Fold	Best Fold	Test Accuracy	AUC Score
K=3 (tanpa augmentasi)	Acc: 0.9306 Loss: 0.1732	Acc: 0.9358 Loss: 0.1513	110.02 detik	2	0.93	0.9849
K=3 (dengan augmentasi)	Acc: 0.9224 Loss: 0.2019	Acc: 0.9327 Loss: 0.1810	122.27 detik	2	0.93	0.9864
K=5 (tanpa augmentasi)	Acc: 0.9459 Loss: 0.1486	Acc: 0.9643 Loss: 0.1124	107.51 detik	1	0.93	0.9886
K=5 (dengan augmentasi)	Acc: 0.9459 Loss: 0.1550	Acc: 0.9592 Loss: 0.1151	196.25 detik	1	0.92	0.9776

K=10 (tanpa augmentasi)	Acc: 0.9378 Loss: 0.1631	Acc: 0.9694 Loss: 0.1245	114.38 detik	1	0.93	0.9754
K=10 (dengan augmentasi)	Acc: 0.9276 Loss: 0.1949	Acc: 0.9796 Loss: 0.1303	120.84 detik	4	0.94	0.9761

Eksperimen menunjukkan bahwa penggunaan K=5 tanpa *augmentasi* memberikan performa terbaik secara keseluruhan, dengan akurasi validasi rata-rata tertinggi (94.59%), akurasi validasi terbaik (96.43%), dan skor AUC tertinggi pada data uji (0.9886). Meskipun *augmentasi* cenderung meningkatkan kemampuan generalisasi, dalam kasus ini justru sedikit menurunkan akurasi dan memperpanjang waktu pelatihan. Sementara itu, model K=10 dengan *augmentasi* mencatat akurasi uji tertinggi (94%), namun skor AUC-nya lebih rendah dari K=5. Hal ini menunjukkan bahwa *augmentasi* tidak selalu memberikan keuntungan, dan pemilihan nilai K dan penggunaan *augmentasi* harus disesuaikan dengan tujuan akhir

4. 8 Diskusi Penelitian

Penelitian ini menggunakan pendekatan deep learning untuk merancang model Convolutional Neural Network (CNN) dengan segmentasi menggunakan arsitektur U-Net dan klasifikasi menggunakan DenseNet121 yang sudah dikonfigurasi pada poin-poin sebelumnya. Penerapan model segmentasi U-Net dalam pre-processing sebelum masuk ke pemodelan klasifikasi DenseNet dinilai cukup baik dalam memisahkan area paru-paru dengan area lainnya. Evaluasi segmentasi menggunakan *dice coefficient* menunjukkan bahwa tumpang tindih antara *mask* prediksi dan *ground truth* mencapai hampir 94%. Didukung dengan visualisasi gambar 4. 13 yang menggunakan sample acak memberikan nilai *dice coefficient* sebesar 0.9344 mencerminkan tingkat tumpang tindih yang sangat baik. Ini menegaskan bahwa model mampu melakukan segmentasi paru-paru dengan akurasi tinggi pada gambar tersebut.

Pada kasus klasifikasi yang berbasis arsitektur DenseNet121 juga menunjukkan bahwa model sangat baik dalam membedakan antara kedua kelas (Normal dan Tuberkulosis). Ini didukung dengan beberapa metrik evaluasi yang menunjukkan hasil yang memuaskan dengan tingkat akurasi 94,3% menegaskan bahwa model dapat membedakan kedua kelas dengan bagus dan robust, mencerminkan kinerja yang andal dalam melakukan klasifikasi tuberkulosis pada data x-ray dada. Selain itu, metrik evaluasi ROC dan AUC juga memberikan nilai AUC sebesar 0.98, ini menunjukkan bahwa kemampuan model dalam memisahkan kedua kelas sangat baik.

Performa pelatihan pada training set menunjukkan hasil yang sangat baik, selaras dengan performa pada validasi set menandakan model ini tidak mengalami *overfitting*. Hal ini didapatkan dari penggunaan *transfer learning* dengan bobot *pretraining* dari *ImageNet* dan seluruh lapisan dasar dibekukan untuk menjaga fitur umum yang telah dipelajari sebelumnya. penggunaan *dropout* sebesar 0.3 ditambahkan untuk mengurangi ketergantungan antar *neuron*. *Data augmentation* memperluas variasi data pelatihan secara sintetis, selain itu *early stopping* menghentikan pelatihan jika validasi loss tidak membaik. Terakhir, *10-fold cross-validation* digunakan untuk memastikan evaluasi model yang lebih stabil dan general. Pendekatan ini secara sinergis menjaga performa dan menghindari *overfitting*.

Teknik *random undersampling* menggunakan diterapkan pada data yang digunakan untuk menangani *label imbalance*, sehingga distribusi data antar kelas normal dan kelas tuberkulosis tergolong seimbang, ini dapat dilihat pada gambar 4. 5 dan gambar 4. 6. Pada bab 4. 2. 2 Resolusi, Resize, dan Normalisasi masalah variasi kualitas citra telah tangani dengan melakukan resolusi, resize dan normalisasi pada setiap gambar yang digunakan, sehingga gambar menjadi seragam. Proses pada subbab 4. 2. 1 Pembersihan data dilakukan untuk menangani noise dengan menghapus data-data yang rusak/inkonsisten dan duplikat, menormalisasi dan validasi label. Penelitian ini menggunakan dataset yang bersumber dari berbagai daerah dengan anatomi pasien yang bervariasi, dengan hasil yang didapatkan menunjukkan bahwa model yang digunakan berhasil

menangani variasi anatomi pasien. Dengan demikian, penelitian ini berhasil menjawab rumusan masalah pertama yaitu mengembangkan sistem klasifikasi Tuberkulosis berbasis X-ray yang akurat, relevan, mampu mengatasi masalah overfitting, ketidakseimbangan kelas, variasi kualitas citra, variasi anatomi, serta noise. Hasil ini juga menunjukkan bahwa penelitian berhasil mencapai tujuan penelitian pertama.

Selanjutnya, studi ini juga menjawab rumusan masalah kedua yaitu meningkatkan transparansi pada model sehingga mendapatkan kepercayaan pada hasil deteksi Tuberkulosis berbasis X-ray dan membantu proses diagnosis. Dengan adanya visualisasi heatmap menggunakan Grad-CAM dapat meningkatkan transparansi model klasifikasi DenseNet121 dan meningkatkan kepercayaan pada hasil deteksi, karena visualisasi Grad-CAM menampilkan gradient berwarna yang akan menyoroti area yang paling mempengaruhi hasil prediksi. Ini dapat membantu proses diagnosis lebih lanjut, dengan demikian tujuan penelitian kedua berhasil dicapai.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Penelitian ini berhasil menerapkan arsitektur *Convolutional Neural Network* (CNN) DenseNet121 dalam mengklasifikasi citra x-ray dada menjadi dua kelas (Normal dan Tuberkulosis). Model dikembangkan menggunakan dua sumber data utama yang berasal dari platform Kaggle yang disediakan khusus untuk deteksi tuberkulosis sehingga data yang digunakan sesuai dengan kebutuhan penelitian. Setelah data terkumpul, dilakukan eksplorasi untuk mempelajari data-data yang akan digunakan. Kemudian, proses pre-processing dilakukan secara menyeluruh, mencakup impor dan eksplorasi data, resolusi dan resize ukuran data citra menjadi bentuk (224, 224, 3), normalisasi nilai piksel ke rentang 0 sampai 1. Penerapan segmentasi yang akan memisahkan area paru-paru dengan area lain. Serta penerapan teknik augmentasi data guna memperkaya variasi visual dalam data pelatihan. Pembagian data dilakukan secara proporsional menjadi data latih (70%), validasi (15%), dan data uji (15%), penggunaan stratifikasi berdasarkan label bertujuan agar proporsi kelas tetap konsisten pada setiap subset, sehingga model dapat dilatih dan dievaluasi dengan data yang representatif dan menghindari bias label.

Model dilatih menggunakan konfigurasi yang telah ditentukan, meliputi *batch size* sebesar 8, *learning rate* 0.001, *optimizer Adam*, *epoch* 25, dan fungsi *loss binary crossentropy*. Hasil evaluasi menunjukkan bahwa model mampu mencapai akurasi sebesar 94,3% dan performa yang seimbang pada kedua kelas. Untuk kelas 0 (Normal) dengan *support* sebanyak 105 gambar, model mencapai *Precision* sebesar 0.93, *Recall* 0.96, dan *F1-Score* 0.94, menandakan kemampuan yang sangat baik dalam mengenali citra normal tanpa banyak kesalahan negatif. Sementara itu, pada kelas 1 (Tuberkulosis) dengan jumlah *support* yang sama, *Precision* mencapai 0.96, *Recall* 0.92, dan *F1-Score* 0.94. Meskipun model sangat presisi dalam mengklasifikasi kasus tuberkulosis, nilai *recall* yang sedikit lebih rendah menunjukkan adanya beberapa kasus tuberkulosis yang tidak terdeteksi. Secara

keseluruhan, model menunjukkan performa kuat dengan potensi untuk digunakan dalam sistem bantu diagnosis, meskipun penguatan pada deteksi sensitivitas kelas tuberkulosis masih dapat ditingkatkan.

Evaluasi menggunakan *Confusion Matrix* menunjukkan bahwa mayoritas klasifikasi dilakukan dengan tepat, dan kesalahan yang terjadi tersebar merata di antara kelas. Evaluasi lanjutan melalui metrik lain seperti kurva ROC dan nilai AUC, semakin menegaskan kemampuan model dalam membedakan tiap kelas dengan akurasi tinggi. Nilai AUC yang sebesar 0.98 mengindikasikan sensitivitas dan spesifisitas model yang sangat baik dalam klasifikasi.

Secara keseluruhan, hasil dari penelitian ini menunjukkan bahwa arsitektur DenseNet121 merupakan pendekatan yang cukup efektif dan dapat diandalkan untuk melakukan tugas klasifikasi tuberkulosis. Dengan penerapan preprocessing yang tepat, konfigurasi pelatihan yang optimal, serta pemanfaatan dataset yang bervariasi, model mampu menghasilkan performa tinggi dan generalisasi yang baik. Berdasarkan subbab 4. 8 Diskusi Penelitian, didapatkan bahwa penelitian ini berhasil menjawab semua rumusan masalah, dan mencapai semua tujuan penelitian. Oleh karena itu, sistem klasifikasi berbasis CNN ini memiliki potensi besar untuk diimplementasikan dalam bidang medis khususnya untuk kasus klasifikasi tuberkulosis secara digital.

5. 2 Saran

Berdasarkan penelitian ini, terdapat beberapa langkah yang dapat diambil untuk meningkatkan kinerja model dalam klasifikasi citra medis dan memperluas pengaplikasiannya. Saran-saran berikut ini diharapkan dapat menjadi arah pengembangan lebih lanjut dalam penelitian dan aplikasi model ini.

1. Perluasan Dataset dan Peningkatan Arsitektur

Untuk meningkatkan akurasi dan generalisasi model, disarankan untuk memperluas cakupan dataset dengan lebih banyak variasi citra X-ray dari berbagai sumber dan kondisi klinis. Hal ini termasuk menambah data dari berbagai jenis kelainan paru atau populasi geografis yang berbeda, sehingga

model tidak hanya belajar dari pola data yang homogen. Selain itu, pengembangan arsitektur dapat dilakukan dengan menguji model deep learning yang lebih kompleks seperti EfficientNet, Vision Transformer (ViT), atau ResNeSt. Penerapan mekanisme attention seperti CBAM atau SE-Block juga dapat meningkatkan fokus model terhadap area penting dalam citra. Kombinasi ini diyakini dapat memperbaiki akurasi serta ketahanan model terhadap noise atau variasi data dunia nyata. Penggabungan ensemble model juga bisa menjadi strategi lanjutan untuk mengurangi kesalahan klasifikasi dan meningkatkan stabilitas prediksi.

2. Peningkatan Komputasi

Salah satu kendala dalam penelitian ini adalah keterbatasan sumber daya komputasi yang menyebabkan waktu pelatihan menjadi cukup lama. Oleh karena itu, saran yang dapat diberikan untuk penelitian selanjutnya adalah menerapkan paralelisasi pelatihan menggunakan multi-GPU atau integrasi dengan High Performance Computing (HPC). Dengan pendekatan seperti PyTorch DistributedDataParallel atau Horovod, beban pelatihan dapat dibagi sehingga proses training yang sebelumnya memakan waktu berjam-jam dapat dipercepat menjadi hanya beberapa menit. Selain itu, pemanfaatan layanan cloud computing seperti Google Colab Pro, AWS, atau Azure juga dapat menjadi alternatif yang efisien dan fleksibel. Peningkatan komputasi ini sangat penting untuk menangani model kompleks dan dataset besar, serta memungkinkan eksplorasi arsitektur dan tuning hyperparameter secara lebih optimal tanpa terganggu oleh keterbatasan hardware dan software gratisan.

3. Penyesuaian Explainable AI (XAI)

Untuk meningkatkan interpretabilitas model, perlu dilakukan penyesuaian pada implementasi Grad-CAM agar hasil visualisasi lebih mudah dipahami oleh tenaga medis. Misalnya, dengan memperbaiki resolusi peta aktivasi, menggunakan skema pewarnaan yang lebih intuitif, dan menyesuaikan layer target agar fokus pada fitur klinis yang relevan. Selain Grad-CAM, disarankan menambahkan metode XAI lain seperti LIME dan SHAP yang dapat memberikan perspektif berbeda terhadap keputusan model. Keduanya dapat

digunakan untuk data citra dan membantu dalam menilai kontribusi piksel atau region terhadap output klasifikasi. Kombinasi beberapa teknik XAI akan menghasilkan pemahaman yang lebih komprehensif dan validasi silang antar-metode. Ini tidak hanya untuk keperluan akademik, tetapi juga agar model dapat lebih dipercaya dan digunakan dalam praktik klinis secara nyata, khususnya dalam sistem CAD (Computer-Aided Diagnosis).

4. Penambahan Generative AI

Langkah pengembangan selanjutnya adalah integrasi Generative AI berbasis LLM (Large Language Model) untuk menghasilkan laporan medis otomatis. Setelah model mengklasifikasi kondisi sebagai normal atau tuberkulosis, sistem dapat memberikan deskripsi kondisi secara otomatis, termasuk perkiraan tingkat keparahan penyakit—ringan, sedang, atau berat. Ini dapat dicapai dengan menggabungkan hasil klasifikasi dengan sistem NLG (Natural Language Generation) berbasis model seperti GPT atau BioBERT yang telah dilatih dengan data laporan medis. Pendekatan ini tidak hanya meningkatkan efisiensi kerja tenaga medis, tetapi juga membantu memberikan penjelasan naratif yang konsisten terhadap hasil prediksi model. Generative AI juga dapat digunakan untuk membuat penjelasan keputusan model lebih manusiawi dan mendekati penalaran klinis, yang akan sangat berguna untuk dokumentasi medis dan telemedicine.

DAFTAR PUSTAKA

- Alfina, I., Azzahra, A., Setiawan, A., 2024. INOVASI TEKNOLOGI AI DALAM DETEKSI DINI TUBERKULOSIS DENGAN KECERDASAN BUATAN, Jurnal Multilingual.
- Ataş, İ., 2023. Performance Evaluation of Jaccard-Dice Coefficient on Building Segmentation from High Resolution Satellite Images. Balkan Journal of Electrical and Computer Engineering 11, 100–106. <https://doi.org/10.17694/bajece.1212563>
- Aviana, F., Jati, S.P., Budiyantri, R.T., 2021. SYSTEMATIC REVIEW PELAKSANAAN PROGRAMMATIC MANAGEMENT OF DRUG-RESISTANT TUBERCULOSIS PADA PASIEN TUBERKULOSIS RESISTAN OBAT. Jurnal Kesehatan Masyarakat (Undip) 9, 215–222. <https://doi.org/10.14710/jkm.v9i2.28719>
- Balam, V.P., Sameer, V.U., Chinara, S., 2021. Automated classification system for drowsiness detection using convolutional neural network and electroencephalogram. IET Intelligent Transport Systems 15, 514–524. <https://doi.org/10.1049/itr2.12041>
- Behzadi-khormouji, H., Rostami, H., Salehi, S., Derakhshande-Rishehri, T., Masoumi, M., Salemi, S., Keshavarz, A., Gholamrezanezhad, A., Assadi, M., Batouli, A., 2020. Deep learning, reusable and problem-based architectures for detection of consolidation on chest X-ray images. Comput Methods Programs Biomed 185, 105162. <https://doi.org/10.1016/j.cmpb.2019.105162>
- Bhandari, M., Shahi, T.B., Siku, B., Neupane, A., 2022a. Explanatory classification of CXR images into COVID-19, Pneumonia and Tuberculosis using deep learning and XAI. Comput Biol Med 150. <https://doi.org/10.1016/j.compbiomed.2022.106156>
- Bhandari, M., Shahi, T.B., Siku, B., Neupane, A., 2022b. Explanatory classification of CXR images into COVID-19, Pneumonia and Tuberculosis using deep learning and XAI. Comput Biol Med 150. <https://doi.org/10.1016/j.compbiomed.2022.106156>

- Bojer, C.S., Meldgaard, J.P., 2021. Kaggle forecasting competitions: An overlooked learning opportunity. *Int J Forecast* 37, 587–603. <https://doi.org/10.1016/j.ijforecast.2020.07.007>
- Cai, G., 2024. Advanced Image Classification Using Convolutional Neural Networks. *Science and Technology of Engineering, Chemistry and Environmental Protection* 1. <https://doi.org/10.61173/117trk02>
- Çallı, E., Sogancioglu, E., van Ginneken, B., van Leeuwen, K.G., Murphy, K., 2021. Deep learning for chest X-ray analysis: A survey. *Med Image Anal* 72, 102125. <https://doi.org/10.1016/j.media.2021.102125>
- Caterson, J., Lewin, A., Williamson, E., 2024. The application of explainable artificial intelligence (XAI) in electronic health record research: A scoping review. *Digit Health*. <https://doi.org/10.1177/20552076241272657>
- Dendi Maysanjaya, I.M., 2020. Klasifikasi Pneumonia pada Citra X-rays Paru-paru dengan Convolutional Neural Network (Classification of Pneumonia Based on Lung X-rays Images using Convolutional Neural Network), *Jurnal Nasional Teknik Elektro dan Teknologi Informasi* |.
- Di Martino, F., Delmastro, F., 2023. Explainable AI for clinical and remote health applications: a survey on tabular and time series data. *Artif Intell Rev* 56, 5261–5315. <https://doi.org/10.1007/s10462-022-10304-3>
- Diar, R.M., Fu'Adah, R.Y.N., Usman, K., 2022. Klasifikasi Penyakit Paru-Paru Berbasis Pengolahan Citra X Ray Menggunakan Convolutional Neural Network (Classification Of The Lung Diseases Based On X Ray Image Processing Using Convolutional Neural Network).
- Dietterich, T.G., 2000. *Ensemble Methods in Machine Learning*. pp. 1–15. https://doi.org/10.1007/3-540-45014-9_1
- Famiglini, L., Campagner, A., Barandas, M., La Maida, G.A., Gallazzi, E., Cabitza, F., 2024. Evidence-based XAI: An empirical approach to design more effective and explainable decision support systems. *Comput Biol Med* 170. <https://doi.org/10.1016/j.combiomed.2024.108042>
- Gading Rayya Samita, Wisesa, W., Setiawan, E.D., Respati K, I., Hidayat, R., 2024. Integrasi Artificial Intelligence dan Teori Bounded Rationality dalam

- Mengatasi Ketidakpastian Pengambilan Keputusan Bisnis di Era Big Data. *Jurnal Bisnis dan Komunikasi Digital* 2, 12. <https://doi.org/10.47134/jbk.d.v2i2.3460>
- GeeksforGeeks, 2024. Data Preprocessing in Data Mining [WWW Document]. Geeks for Geeks. URL <https://www.geeksforgeeks.org/data-preprocessing-in-data-mining/> (accessed 12.23.24).
- Gefters, W.B., Post, B.A., Hatabu, H., 2023. Commonly Missed Findings on Chest Radiographs. *Chest* 163, 650–661. <https://doi.org/10.1016/j.chest.2022.10.039>
- Gipiškis, R., Tsai, C.-W., Kurasova, O., 2024. Explainable AI (XAI) in Image Segmentation in Medicine, Industry, and Beyond: A Survey. <https://doi.org/10.1016/j.ict.e.2024.09.008>
- Gozes, O., Greenspan, H., 2019. Deep Feature Learning from a Hospital-Scale Chest X-ray Dataset with Application to TB Detection on a Small-Scale Dataset, in: 2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC). IEEE, pp. 4076–4079. <https://doi.org/10.1109/EMBC.2019.8856729>
- Gu, J., Wang, Z., Kuen, J., Ma, L., Shahroudy, A., Shuai, B., Liu, T., Wang, X., Wang, G., Cai, J., Chen, T., 2018. Recent advances in convolutional neural networks. *Pattern Recognit* 77, 354–377. <https://doi.org/10.1016/j.patcog.2017.10.013>
- Hajian-Tilaki, K., 2013. Receiver Operating Characteristic (ROC) Curve Analysis for Medical Diagnostic Test Evaluation, *Caspian J Intern Med*.
- Hassan, S.U., Abdulkadir, S.J., Zahid, M.S.M., Al-Selwi, S.M., 2025. Local interpretable model-agnostic explanation approach for medical imaging analysis: A systematic literature review. *Comput Biol Med* 185, 109569. <https://doi.org/10.1016/j.combiomed.2024.109569>
- Iqbal, A., Usman, M., Ahmed, Z., 2023. Tuberculosis chest X-ray detection using CNN-based hybrid segmentation and classification approach. *Biomed Signal Process Control* 84, 104667. <https://doi.org/10.1016/j.bspc.2023.104667>

- Jasman, T.Z., Fadhlullah, M.A., Pratama, A.L., Rismayani, R., 2022. Analisis Algoritma Gradient Boosting, Adaboost dan Catboost dalam Klasifikasi Kualitas Air. *Jurnal Teknik Informatika dan Sistem Informasi* 8. <https://doi.org/10.28932/jutisi.v8i2.4906>
- Jha, S., Son, L.H., Kumar, R., Priyadarshini, I., Smarandache, F., Long, H.V., 2019. Neutrosophic image segmentation with Dice Coefficients. *Measurement (Lond)* 134, 762–772. <https://doi.org/10.1016/j.measurement.2018.11.006>
- Kadiyala, A., Kumar, A., 2017. Applications of Python to evaluate environmental data science problems. *Environ Prog Sustain Energy* 36, 1580–1586. <https://doi.org/10.1002/ep.12786>
- Kaggle, 2010. Kaggle: Your Home for Data Science. [WWW Document]. URL <https://www.kaggle.com/> (accessed 1.22.25).
- Kemenkes, 2021. Merokok, Penyebab Utama Penyakit Paru Obstruktif Kronis [WWW Document]. <https://kemkes.go.id>. URL <https://kemkes.go.id/eng/merokok-penyebab-utama-penyakit-paru-obstruktif-kronis> (accessed 10.12.24).
- Kharis, S.A.A., Zili, A.H.A., Fajar, F.I., Putri, A., Arisanty, M., 2024. Literature Review to Evaluate the Impact of Machine Learning and Artificial Intelligence for Lung Cancer Patient in COVID-19 Pandemic. *G-Tech: Jurnal Teknologi Terapan* 8, 576–583. <https://doi.org/10.33379/gtech.v8i1.3891>
- Kim, H.E., Cosa-Linan, A., Santhanam, N., Jannesari, M., Maros, M.E., Ganslandt, T., 2022. Transfer learning for medical image classification: a literature review. *BMC Med Imaging*. <https://doi.org/10.1186/s12880-022-00793-7>
- Kovari, A., 2025. Explainable AI chatbots towards XAI ChatGPT: A review. *Heliyon*. <https://doi.org/10.1016/j.heliyon.2025.e42077>
- Kristian Wilianto, 2021. Elemen Penting dalam Deep Learning for Computer Vision yang Harus Diketahui Sebelum Membuat Model Pertamamu! [WWW Document]. Medium. URL <https://medium.com/data-folks-indonesia/element-penting-dalam-deep-learning-for-computer-vision-yang-harus-diketahui-sebelum-membuat-model-d74b1befb1d0> (accessed 11.3.24).

- Leonard, C.R., Nurtanio, I., Bustamin, A., 2024. Systematic Literature Review: Deep Learning Pada Citra Sinar-X Paru Untuk Klasifikasi Penyakit. *Techno.Com* 23, 512–531. <https://doi.org/10.62411/tc.v23i3.10961>
- Li, Z., Liu, F., Yang, W., Peng, S., Zhou, J., 2022. A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects. *IEEE Trans Neural Netw Learn Syst* 33, 6999–7019. <https://doi.org/10.1109/TNNLS.2021.3084827>
- Liebenberg, D., Gordhan, B.G., Kana, B.D., 2022. Drug resistant tuberculosis: Implications for transmission, diagnosis, and disease management. *Front Cell Infect Microbiol* 12. <https://doi.org/10.3389/fcimb.2022.943545>
- Liu, J., Huang, Y., 2020. Comparison of different CNN models in tuberculosis detecting. *KSII Transactions on Internet and Information Systems* 14, 3519–3533. <https://doi.org/10.3837/tiis.2020.08.021>
- Liu, W., Luo, J., Yang, Y., Wang, W., Deng, J., Yu, L., 2022. Automatic lung segmentation in chest X-ray images using improved U-Net. *Sci Rep* 12. <https://doi.org/10.1038/s41598-022-12743-y>
- Mahesh, B., 2020. Machine Learning Algorithms - A Review. *International Journal of Science and Research (IJSR)* 9, 381–386. <https://doi.org/10.21275/ART20203995>
- Nazir, M.I., Akter, A., Hussen Wadud, M.A., Uddin, M.A., 2024. Utilizing customized CNN for brain tumor prediction with explainable AI. *Heliyon* 10. <https://doi.org/10.1016/j.heliyon.2024.e38997>
- Nusantara, B.S., Akbar, M., 2024. Klasifikasi Penyakit Tuberculosis Berdasarkan Citra Rontgen Thorax Menggunakan Multi-Scale Convolutional Neural Network. *sudo Jurnal Teknik Informatika* 3, 1–8. <https://doi.org/10.56211/sudo.v3i1.483>
- Obaidan, H. Bin, Hussain, M., AlMajed, R., 2024. EEG_DMNet: A Deep Multi-Scale Convolutional Neural Network for Electroencephalography-Based Driver Drowsiness Detection. *Electronics (Basel)* 13, 2084. <https://doi.org/10.3390/electronics13112084>

- Rahman, T., Khandakar, A., Kadir, M.A., Islam, K.R., Islam, K.F., Mazhar, R., Hamid, T., Islam, M.T., Kashem, S., Mahbub, Z. Bin, Ayari, M.A., Chowdhury, M.E.H., 2020. Reliable Tuberculosis Detection Using Chest X-Ray With Deep Learning, Segmentation and Visualization. *IEEE Access* 8, 191586–191601. <https://doi.org/10.1109/ACCESS.2020.3031384>
- Ramzan, M., Abid, A., Fayyaz, M., Alahmadi, T.J., Nobanee, H., Rehman, A., 2024. A Novel Hybrid Approach for Driver Drowsiness Detection Using a Custom Deep Learning Model. *IEEE Access* 12, 126866–126884. <https://doi.org/10.1109/ACCESS.2024.3438617>
- Ridlo Hanifudin Tahier, A., Prayugo Hariyanto, A., Much Azam, M., 2023. DETEKSI KANKER PARU MENGGUNAKAN SEGMENTASI CITRA CT-SCAN DENGAN ALGORITMA KLUSTER K-MEANS. *BERKALA FISIKA*; Vol 26, No 2 (2023): Berkala Fisika 34–45.
- Rochmawanti, O., Utaminingrum, F., Bachtiar, F.A., 2021. Analisis Performa Pre-Trained Model Convolutional Neural Network dalam Mendeteksi Penyakit Tuberkulosis. *Jurnal Teknologi Informasi dan Ilmu Komputer* 8, 805–814. <https://doi.org/10.25126/jtiik.2021844441>
- Sapto, J., Jurusan, P., Politeknik, K., Kemenkes, K., Timur, K., 2021. TINJAUAN LITERATUR: FAKTOR RISIKO PENINGKATAN ANGKA INSIDENSI TUBERKULOSIS. *Jurnal Ilmiah Pannmed*.
- Sarang Narkhede, 2018. Understanding AUC - ROC Curve [WWW Document]. Medium. URL <https://medium.com/data-science/understanding-auc-roc-curve-68b2303cc9c5> (accessed 11.3.24).
- Sharma, V., Nillmani, Gupta, S.K., Shukla, K.K., 2024. Deep learning models for tuberculosis detection and infected region visualization in chest X-ray images. *Intelligent Medicine* 4, 104–113. <https://doi.org/10.1016/j.imed.2023.06.001>
- Shim, J.H., Kim, W.S., Kim, K.G., Yee, G.T., Kim, Y.J., Jeong, T.S., 2022. Evaluation of U-Net models in automated cervical spine and cranial bone segmentation using X-ray images for traumatic atlanto-occipital dislocation diagnosis. *Sci Rep* 12. <https://doi.org/10.1038/s41598-022-23863-w>

- Singh, P., Singh, N., Singh, K.K., Singh, A., 2021. Diagnosing of disease using machine learning, in: *Machine Learning and the Internet of Medical Things in Healthcare*. Elsevier, pp. 89–111. <https://doi.org/10.1016/B978-0-12-821229-5.00003-3>
- Stahlschmidt, S.R., Ulfenborg, B., Synnergren, J., 2022. Multimodal deep learning for biomedical data fusion: A review. *Brief Bioinform.* <https://doi.org/10.1093/bib/bbab569>
- T, T., Haryono, W., Zailani, A.U., Djaksana, Y.M., Rosmawarni, N., Arianti, N.D., 2023. Transformers in Machine Learning: Literature Review. *Jurnal Penelitian Pendidikan IPA* 9, 604–610. <https://doi.org/10.29303/jppipa.v9i9.5040>
- Too, E.C., Mwathi, D.G., Gitonga, L.K., Mwaka, P., Kinyori, S., 2024. An X-ray image-based pruned dense convolution neural network for tuberculosis detection. *Computer Methods and Programs in Biomedicine Update* 6. <https://doi.org/10.1016/j.cmpbup.2024.100169>
- Truong Thanh Nguyen, H., Cao, H., Vo Thanh Nguyen, K., Dinh Khoi Pham, N., 2021. Evaluation of Explainable Artificial Intelligence: SHAP, LIME, and CAM Evaluation of Explainable Artificial Intelligence: SHAP, LIME, and CAM Hung Quoc Cao.
- Vimbi, V., Shaffi, N., Mahmud, M., 2024. Interpreting artificial intelligence models: a systematic review on the application of LIME and SHAP in Alzheimer's disease detection. *Brain Inform.* <https://doi.org/10.1186/s40708-024-00222-1>
- Vitrosens, 2023. What is Mycobacterium Tuberculosis (TB)? How to Use Mycobacterium Tuberculosis (TB) Detection qPCR Kit? [WWW Document]. Vitrosens. URL <https://vitrosens.com/what-is-mycobacterium-tuberculosis-tb-how-to-use-mycobacterium-tuberculosis-tb-detection-qpcr-kit> (accessed 10.25.24).
- Wahyuningrum, R.T., Jannah, M., Satoto, B.D., Sari, A.K., Sensusiaty, A.D., 2023. Segmentasi Citra X-Ray Dada Menggunakan Metode Modifikasi Deeplabv3+. *Jurnal Teknologi Informasi dan Ilmu Komputer* 10, 687–698. <https://doi.org/10.25126/jtiik.20231036754>

- Wijaya Kusuma, W., Rizal Isnanto, R., Fauzi, A., Korespondensi, P., 2023. ANALISIS PERBANDINGAN MODEL CNN VGG16 DAN DENSENET121 MENGGUNAKAN KERANGKA KERJA TENSORFLOW UNTUK DETEKSI JENIS HEWAN. *Jurnal Teknik Komputer* 1, 141–147. <https://doi.org/10.14710/jtk.v1i4.37009>
- Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Le Scao, T., Gugger, S., Drame, M., Lhoest, Q., Rush, A., 2020. Transformers: State-of-the-Art Natural Language Processing, in: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. Association for Computational Linguistics, Stroudsburg, PA, USA, pp. 38–45. <https://doi.org/10.18653/v1/2020.emnlp-demos.6>
- World Health Organization, 2022. Fakta-fakta utama [WWW Document]. <https://www.who.int>. URL <https://www.who.int/indonesia/news/campaign/tb-day-2022/fact-sheets> (accessed 10.12.24).
- Yan, B., Pei, M., 2022. Clinical-BERT: Vision-Language Pre-training for Radiograph Diagnosis and Reports Generation. *Proceedings of the AAAI Conference on Artificial Intelligence* 36, 2982–2990. <https://doi.org/10.1609/aaai.v36i3.20204>
- Yousef, R., Khan, S., Gupta, G., Siddiqui, T., Albahlal, B.M., Alajlan, S.A., Haq, M.A., 2023. U-Net-Based Models towards Optimal MR Brain Image Segmentation. *Diagnostics* 13. <https://doi.org/10.3390/diagnostics13091624>
- Zhou, W., Cheng, G., Zhang, Z., Zhu, L., Jaeger, S., Lure, F.Y.M., Guo, L., 2022. Deep learning-based pulmonary tuberculosis automated detection on chest radiography: large-scale independent testing. *Quant Imaging Med Surg* 12, 2344–2355. <https://doi.org/10.21037/qims-21-676>